

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH

ĐIỂM SỐ	ĐIỂM CHỮ	Cán bộ chấm thi 1 <i>(Kí, ghi rõ họ tên)</i>	Cán bộ chấm thi 2 <i>(Kí, ghi rõ họ tên)</i>

TIỂU LUẬN HỌC PHẦN
HỌC SÂU

TÊN ĐỀ TÀI DÒNG MỘT
TÊN ĐỀ TÀI DÒNG HAI
TÊN ĐỀ TÀI DÒNG BA

Ngành: Khoa học máy tính

Khóa: 36 (2025 – 2027)

Giảng viên giảng dạy:

Tên học viên: Huỳnh Phát Lợi

Mã số học viên: KHMT836016

Thành phố Hồ Chí Minh, tháng 08 năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH



TIỂU LUẬN HỌC PHẦN
HỌC SÂU

TÊN ĐỀ TÀI DÒNG MỘT
TÊN ĐỀ TÀI DÒNG HAI
TÊN ĐỀ TÀI DÒNG BA

Ngành: Khoa học máy tính

Khóa: 36 (2025 – 2027)

Giảng viên giảng dạy:

Tên học viên: Huỳnh Phát Lợi

Mã số học viên: KHMT836016

Thành phố Hồ Chí Minh, tháng 08 năm 2026

LỜI CAM ĐOAN

Tôi xin cam đoan bài tiểu luận với đề tài “TÊN ĐỀ TÀI VIẾT HOA TOÀN BỘ ĐẶT TẠI ĐÂY” là kết quả nghiên cứu và thực hiện của cá nhân tôi dưới sự hướng dẫn của giảng viên phụ trách học phần.

Các nội dung trình bày trong bài tiểu luận được tổng hợp, phân tích và diễn giải dựa trên quá trình tìm hiểu tài liệu, nghiên cứu phương pháp và thực nghiệm đánh giá. Các tài liệu, công trình nghiên cứu, dữ liệu và nguồn tham khảo được sử dụng trong bài đều được trích dẫn và ghi rõ trong phần tài liệu tham khảo.

Tôi cam đoan rằng bài tiểu luận không sao chép nguyên văn từ bất kỳ công trình nào khác. Các thực nghiệm được thực hiện trung thực, có cơ sở kiểm chứng và có thể tái lập. Mọi sai sót, nếu có, thuộc trách nhiệm của cá nhân tôi.

Thành phố Hồ Chí Minh, ngày 06 tháng 08 năm 2026

Học viên thực hiện

(Ký và ghi rõ họ tên)

Huỳnh Phát Lợi

LỜI CẢM ƠN

Trước hết, tôi xin gửi lời cảm ơn chân thành đến quý thầy cô phụ trách học phần HỌC SÂU, đã tận tình giảng dạy, định hướng và cung cấp những kiến thức nền tảng quan trọng cho đề tài này.

Những kiến thức về kiến trúc mạng nơ-ron tích chập, cơ chế chú ý và các phương pháp đánh giá mô hình được truyền đạt trong học phần đã giúp tôi có cơ sở để tiếp cận đề tài “TÊN ĐỀ TÀI VIẾT HOA TOÀN BỘ ĐẶT TẠI ĐÂY” một cách có hệ thống hơn, đặc biệt là ở khâu phân tích nguyên nhân đằng sau các con số thay vì chỉ dừng lại ở việc báo cáo kết quả.

Tôi cũng xin cảm ơn các bạn cùng nhóm đã phối hợp trong quá trình xây dựng mã nguồn và tiến hành thực nghiệm, cũng như đã trao đổi thẳng thắn về những kết quả không như kỳ vọng — những trao đổi đó đã góp phần định hình phần phân tích ở Chương 4.

Tôi xin cảm ơn TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH và Khoa Công nghệ Thông tin đã tạo điều kiện học tập, nghiên cứu và cung cấp môi trường học thuật thuận lợi trong quá trình thực hiện bài tiểu luận này.

Do giới hạn về thời gian, tài nguyên tính toán và kinh nghiệm nghiên cứu, bài tiểu luận khó tránh khỏi những thiếu sót; một số hạn chế đã được tôi nêu rõ ở Chương 5. Tôi rất mong nhận được những góp ý từ giảng viên để có thể tiếp tục hoàn thiện nội dung và phát triển đề tài tốt hơn trong các nghiên cứu tiếp theo.

TÓM TẮT

Phát hiện biển báo giao thông là một khối chức năng bắt buộc của hệ thống hỗ trợ lái tiên tiến và xe tự hành. Điểm khó của bài toán không nằm ở việc đạt một chỉ số mAP cao trên tập kiểm tra, mà ở chỗ mô hình phải chạy được trên phần cứng nhúng gắn trên xe, nơi bộ nhớ và ngân sách năng lượng đều bị giới hạn nghiêm ngặt. Điều này dẫn tới nhu cầu *nén mô hình*: làm cho mô hình nhỏ hơn và nhanh hơn mà không đánh mất năng lực phát hiện. Hai kỹ thuật nén phổ biến nhất là chưng cất tri thức và lượng tử hoá sau huấn luyện. Đề tài đặt câu hỏi hai kỹ thuật này thực sự mang lại gì trong bối cảnh một bộ dữ liệu biển báo quy mô vừa, và quan trọng hơn, cái giá phải trả nằm ở đâu.

Đề tài sử dụng bộ dữ liệu *pkdarabi/cardetection* trên Kaggle, gồm 4.969 ảnh độ phân giải 416×416 với 6.012 hộp bao thuộc 15 lớp là đèn tín hiệu và biển giới hạn tốc độ. Trước khi huấn luyện, một phân tích khám phá đầy đủ được thực hiện: phân bố lớp, thống kê kích thước hộp bao, bản đồ nhiệt vị trí vật thể, kiểm tra chất lượng nhãn và kiểm toán rò rỉ dữ liệu giữa các tập. Năm cấu hình được khảo sát trong cùng một lượt chạy: mô hình thầy YOLO26s, mô hình học trò YOLO26n huấn luyện thông thường làm đối chứng, mô hình học trò được chưng cất từ thầy, cùng hai bản xuất sang ONNX ở độ chính xác FP32 và INT8.

Điểm then chốt về mặt phương pháp là toàn bộ năm cấu hình được đánh giá bằng **pycocotools** trên cùng một tập chú thích COCO, nhờ đó ngoài mAP tổng còn thu được *AP* tách riêng cho từng nhóm kích thước vật thể. Ngoài ra, năm ngưỡng chấp nhận được khai báo *trước* khi chạy thực nghiệm, buộc người thực hiện cam kết tiêu chí đánh giá trước khi nhìn thấy số liệu.

Kết quả cho thấy mô hình học trò được chưng cất đạt mAP@0,5 bằng 0,9014, *thấp hơn* mô hình đối chứng huấn luyện thông thường (0,9348) 3,34 điểm phần trăm — một kết quả âm đi ngược giả thuyết ban đầu. Lượng tử hoá INT8 giảm dung lượng tệp 70,3% và chỉ làm mAP@0,5 giảm 0,0038. Tuy nhiên chỉ số tách theo kích thước vật thể cho một bức tranh hoàn toàn khác: cùng phép lượng tử hoá đó làm *AP* trên nhóm vật thể nhỏ giảm 0,0247, tức **gấp 6,5 lần** mức suy giảm của mAP tổng. Trong năm ngưỡng chấp nhận, ba đạt và hai không đạt, cả hai ngưỡng không đạt đều thuộc về giả thuyết chưng cất.

Luận điểm này được kiểm chứng độc lập trên ba đoạn video đường phố ngoài phân

bổ huấn luyện. Vì video không có nhãn thật nên phép kiểm chứng không đo độ chính xác, mà kiểm tra một dự đoán có thể sai: nếu điểm yếu thật nằm ở vật thể nhỏ thì việc tăng độ phân giải đầu vào phải làm lộ thêm các phát hiện nhỏ một cách chọn lọc. Kết quả đúng như dự đoán — nhóm vật thể vừa chỉ tăng 1,4 lần trong khi hai nhóm nhỏ tăng 6,1 và 6,7 lần.

Đóng góp của đề tài không nằm ở một con số mAP cao mà ở hai phát hiện mang tính phương pháp luận. Thứ nhất, mAP tổng che giấu gần như hoàn toàn chi phí thật của các phép nén mô hình; chỉ khi tách AP theo nhóm kích thước mới thấy được rằng toàn bộ suy giảm dồn vào vật thể nhỏ — đúng nhóm quan trọng nhất với bài toán biển báo, nơi biển ở xa quyết định thời gian phản ứng của xe. Thứ hai, phân tích thành phần bộ dữ liệu chỉ ra 38,68% số ảnh là ảnh cắt cận cảnh kiểu GTSRB khiến phân bố kích thước bị lưỡng cực, và kiểm toán rò rỉ phát hiện 10,2% tập kiểm tra có bản sao trong tập huấn luyện. Hạn chế lớn nhất là nhánh chưng cất chạy với kích thước lô nhỏ hơn nhánh đối chứng, một yếu tố gây nhiễu chưa được kiểm soát.

Từ khoá: phát hiện biển báo giao thông, chưng cất tri thức, lượng tử hoá, nén mô hình, vật thể nhỏ, kết quả âm, rò rỉ dữ liệu.

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Diễn giải
ADAS	Advanced Driver Assistance System – Hệ thống hỗ trợ lái tiên tiến
AdamW	Adam with decoupled Weight decay – Thuật toán tối ưu Adam có tách rời suy giảm trọng số
AP	Average Precision – Độ chính xác trung bình
API	Application Programming Interface – Giao diện lập trình ứng dụng
BCE	Binary Cross-Entropy – Hàm mất mát entropy chéo nhị phân
CIoU	Complete Intersection over Union – Độ đo IoU mở rộng dùng cho hồi quy hộp bao
CNN	Convolutional Neural Network – Mạng nơ-ron tích chập
COCO	Common Objects in Context – Bộ dữ liệu và định dạng chú thích chuẩn
CSV	Comma-Separated Values – Định dạng dữ liệu phân tách bằng dấu phẩy
DFL	Distribution Focal Loss – Hàm mất mát tiêu điểm dạng phân phối
FN	False Negative – Trường hợp âm tính giả (bỏ sót)
FP	False Positive – Trường hợp dương tính giả (báo nhầm)
FP16	Floating Point 16-bit – Số thực dấu phẩy động 16 bit
FPN	Feature Pyramid Network – Mạng kim tự tháp đặc trưng

Từ viết tắt	Diễn giải
FPS	Frames Per Second – Số khung hình xử lý được mỗi giây
GFLOPs	Giga Floating Point Operations – Tỷ phép tính dấu phẩy động
GIoU	Generalized Intersection over Union – Độ đo IoU tổng quát hoá
GPU	Graphics Processing Unit – Bộ xử lý đồ họa
GTSDb	German Traffic Sign Detection Benchmark – Bộ chuẩn phát hiện biển báo của Đức
KD	Knowledge Distillation – Chứng cất tri thức
GTSRB	German Traffic Sign Recognition Benchmark – Bộ chuẩn nhận dạng biển báo của Đức
INT8	Integer 8-bit – Số nguyên 8 bit
IoU	Intersection over Union – Tỷ số giao trên hợp giữa hai hộp bao
JSON	JavaScript Object Notation – Định dạng trao đổi dữ liệu dạng văn bản
LR	Learning Rate – Tốc độ học
mAP	mean Average Precision – Độ chính xác trung bình lấy trung bình trên các lớp
NMS	Non-Maximum Suppression – Kỹ thuật loại bỏ hộp bao trùng lặp
ONNX	Open Neural Network Exchange – Định dạng trao đổi mô hình mạng nơ-ron
PR	Precision–Recall – Đường cong độ chính xác theo độ bao phủ

Từ viết tắt	Diễn giải
PTQ	Post-Training Quantization – Lượng tử hoá sau huấn luyện
RGB	Red – Green – Blue – Không gian màu ba kênh
SSD	Single Shot MultiBox Detector – Bộ phát hiện đơn lượt
TP	True Positive – Trường hợp dương tính đúng
VOC	Visual Object Classes – Bộ dữ liệu và định dạng chú thích PASCAL VOC
VRAM	Video Random Access Memory – Bộ nhớ của card đồ hoạ
YOLO	You Only Look Once – Họ mô hình phát hiện đối tượng một giai đoạn

DANH MỤC BẢNG BIỂU

3.1	Thống kê tổng quan bộ dữ liệu theo từng tập	12
3.2	Phân bố lớp chi tiết, sắp theo số hộp bao giảm dần	14
3.3	Phân nhóm kích thước hộp bao theo diện tích chuẩn hoá	15
3.4	Thành phần bộ dữ liệu theo nguồn gốc suy ra từ quy ước đặt tên tệp	16
3.5	Phân vị diện tích hộp bao và cạnh tương ứng trên ảnh 416×416	16
3.6	Năm cấu hình khảo sát và vai trò của từng cấu hình	19
3.7	Siêu tham số huấn luyện và đánh giá	19
4.1	Kết quả năm cấu hình đo bằng pycocotools trên tập kiểm tra	22
4.2	Ba phép so sánh cốt lõi	23
4.3	Kiểm tra các ngưỡng chấp nhận khai báo trước khi chạy thực nghiệm	24
4.4	Ảnh hưởng của việc xuất mô hình và lượng tử hoá	24
4.5	So sánh mức suy giảm giữa mAP tổng và AP trên vật thể nhỏ	25
4.6	Kết quả kiểm toán rò rỉ dữ liệu giữa các tập	27
4.7	Ba video dùng để kiểm chứng	28
4.8	Kết quả trên 87 khung hình mỗi cấu hình, tổng hợp cả ba video	29
4.9	Số phát hiện theo nhóm kích thước và tỉ lệ tăng so với cấu hình A	29
.1	Tài nguyên sử dụng trong đề tài	41
.2	Danh sách 15 lớp và mã tương ứng	41
.3	Ảnh xạ giữa nội dung báo cáo và tệp kết quả sinh ra bởi quy trình	42

DANH MỤC HÌNH ẢNH

3.1	Phân bố số hộp bao theo từng lớp trên toàn bộ dữ liệu	13
3.2	Thống kê kích thước hộp bao trên toàn bộ dữ liệu	15
3.3	Ba chế độ ảnh cùng tồn tại trong bộ dữ liệu, kèm hộp bao nhãn thật	17
3.4	Bản đồ nhiệt vị trí tâm vật thể trên toàn bộ dữ liệu	17
4.1	Ma trận nhầm lẫn chuẩn hoá trên tập kiểm định	26
4.2	Phân bố kích thước vật thể được phát hiện trên video đường thật	29
4.3	Cùng một khung hình của B.mp4 qua hai cấu hình suy luận	31

MỤC LỤC

1	GIỚI THIỆU TỔNG QUAN	1
1.1	Đặt vấn đề	1
1.2	Mục tiêu đề tài	2
1.3	Đối tượng và phạm vi nghiên cứu	3
1.4	Đóng góp của đề tài	3
1.5	Bố cục báo cáo	4
2	CƠ SỞ LÝ THUYẾT VÀ CÔNG TRÌNH LIÊN QUAN	5
2.1	Bài toán phát hiện đối tượng	5
2.1.1	Phát biểu bài toán	5
2.1.2	Định dạng chú thích	5
2.2	Bộ phát hiện một giai đoạn	6
2.2.1	Nguyên lý chung	6
2.2.2	Đa tỉ lệ và vật thể nhỏ	6
2.2.3	Hàm mất mát của họ YOLO hiện đại	6
2.3	Hệ thống độ đo	7
2.3.1	IoU, Precision và Recall	7
2.3.2	mAP	7
2.3.3	AP tách theo nhóm kích thước	8
2.3.4	Độ đo chi phí triển khai	8
2.4	Nén mô hình	9
2.4.1	Chứng cất tri thức	9
2.4.2	Lượng tử hoá	9
2.5	Công trình liên quan về biển báo giao thông	10
3	DỮ LIỆU VÀ PHƯƠNG PHÁP	12
3.1	Bộ dữ liệu	12
3.1.1	Nguồn và quy mô	12
3.1.2	Phân bố lớp và mất cân bằng	13

3.1.3	Thống kê kích thước hộp bao	15
3.1.4	Phân tích thành phần bộ dữ liệu	16
3.1.5	Vị trí vật thể trong khung hình	17
3.1.6	Kiểm tra chất lượng nhãn	18
3.1.7	Kiểm toán rò rỉ dữ liệu giữa các tập	18
3.2	Thiết kế thực nghiệm	18
3.2.1	Năm câu hình khảo sát	18
3.2.2	Siêu tham số	19
3.2.3	Ngưỡng chấp nhận khai báo trước	20
3.2.4	Quy trình đánh giá	20
3.2.5	Bảo đảm tính tái lập	21
4	KẾT QUẢ VÀ BÀN LUẬN	22
4.1	Kết quả tổng quan	22
4.2	Chứng cất tri thức	22
4.2.1	Xác minh cơ chế đã được kích hoạt	22
4.2.2	Kết quả trái với kỳ vọng	23
4.2.3	Kiểm tra ngưỡng chấp nhận	23
4.3	Lượng tử hoá	24
4.3.1	Đánh đổi giữa dung lượng, tốc độ và độ chính xác	24
4.3.2	Chi phí thật nằm ở vật thể nhỏ	25
4.4	Phân tích lỗi	26
4.4.1	Nhầm lẫn giữa các lớp	26
4.4.2	Ảnh hưởng của mất cân bằng lớp	27
4.4.3	Rò rỉ dữ liệu giữa các tập	27
4.5	Kiểm chứng trên video đường thật	27
4.5.1	Thiết kế phép kiểm chứng	28
4.5.2	Kết quả	29
4.5.3	Mức tăng phân bố không đều theo kích thước	29
4.5.4	Các phát hiện thêm có phải dương tính giả không?	30
4.5.5	Quan sát định tính	31
4.6	Bàn luận	31

5	TỔNG KẾT	33
5.1	Tóm lược kết quả đạt được	33
5.2	Đóng góp	33
5.3	Hạn chế	34
5.4	Hướng phát triển	35
	TÀI LIỆU THAM KHẢO	37
	PHỤ LỤC	41
A.	Tài nguyên công khai	41
B.	Danh sách lớp	41
C.	Cách chạy lại quy trình	41
D.	Bảng ánh xạ hình vẽ và nguồn dữ liệu	42
E.	Ghi chú về tính tái lập	43

CHƯƠNG 1 : GIỚI THIỆU TỔNG QUAN

1.1 Đặt vấn đề

Xe tự hành và các hệ thống hỗ trợ lái tiên tiến (ADAS) phải hiểu được môi trường giao thông xung quanh trước khi có thể ra bất kỳ quyết định điều khiển nào. Trong số các thành phần của bài toán nhận thức đó, phát hiện biển báo giao thông giữ một vị trí đặc biệt: biển báo là kênh giao tiếp chính thức giữa hạ tầng đường bộ và người lái, và nội dung của nó ràng buộc trực tiếp hành vi hợp pháp của phương tiện. Một hệ thống bỏ sót biển giới hạn tốc độ hoặc đọc nhầm đèn tín hiệu không chỉ gây khó chịu mà có thể dẫn tới hậu quả về an toàn và pháp lý.

Về mặt kỹ thuật, đây là bài toán phát hiện đối tượng: với mỗi ảnh đầu vào, mô hình phải đồng thời *định vị* từng biển báo bằng một hộp bao và *phân loại* nó vào đúng chủng loại. Các bộ phát hiện một giai đoạn thuộc họ YOLO [1, 2] hiện là lựa chọn mặc định cho ứng dụng thời gian thực nhờ chỉ cần một lượt truyền xuôi.

Tuy nhiên, đạt được một chỉ số mAP cao trên tập kiểm tra mới chỉ là một nửa bài toán. Nửa còn lại — và cũng là nửa quyết định việc hệ thống có triển khai được hay không — là ràng buộc tài nguyên. Máy tính gắn trên xe không có card đồ họa máy chủ; nó có ngân sách bộ nhớ, băng thông và điện năng rất hạn hẹp. Do đó nhu cầu *nén mô hình* trở thành trung tâm: làm sao để mô hình nhỏ hơn và nhanh hơn mà không đánh mất năng lực phát hiện.

Hai họ kỹ thuật nén phổ biến nhất đi theo hai hướng khác nhau. **Chưng cất tri thức** [3] tác động ở khâu huấn luyện: một mô hình học trò nhỏ được dạy bắt chước phân phối đầu ra mềm của một mô hình thầy lớn hơn, với kỳ vọng thu được năng lực vượt quá mức mà kích thước của nó cho phép. **Lượng tử hoá sau huấn luyện** [4] tác động ở khâu triển khai: thay biểu diễn dấu phẩy động bằng biểu diễn số nguyên độ rộng bit thấp hơn, không cần huấn luyện lại.

Cả hai kỹ thuật đều được trình bày rộng rãi kèm những con số hấp dẫn. Nhưng những con số đó gần như luôn được báo cáo dưới dạng *mAP tổng* — và đó chính là điểm mà đề tài này đặt nghi vấn.

Các nút thắt chính mà đề tài phải đối mặt:

1. **Ràng buộc kép giữa độ chính xác và chi phí triển khai.** Mô hình phải đủ nhẹ để chạy trên phần cứng nhúng nhưng vẫn phải đủ chính xác để không bỏ sót biển báo.

2. **mAP tổng có thể là một chỉ số gây hiểu nhầm.** Nó lấy trung bình trên toàn bộ vật thể bất kể kích thước. Nếu phần lớn vật thể trong tập kiểm tra là những trường hợp dễ, một suy giảm nghiêm trọng ở nhóm khó có thể bị pha loãng gần như hoàn toàn.
3. **Vật thể nhỏ.** Biển báo ở xa chỉ chiếm vài chục điểm ảnh trong khung hình, và đây lại chính là trường hợp quyết định thời gian phản ứng của xe. Phát hiện vật thể nhỏ vốn là điểm yếu cố hữu của các bộ phát hiện hiện đại [5].
4. **Dữ liệu quy mô vừa và mất cân bằng.** Bộ dữ liệu sử dụng chỉ có 6.012 hộp bao cho 15 lớp, với tỉ số mất cân bằng giữa lớp phổ biến nhất và lớp hiếm nhất lên tới 35,77 lần [6].
5. **Nguy cơ rò rỉ dữ liệu giữa các tập.** Bộ dữ liệu công khai thường được ghép từ nhiều nguồn và có thể chứa ảnh trùng lặp giữa tập huấn luyện và tập kiểm tra, khiến chỉ số bị thổi phồng [7].

Câu hỏi nghiên cứu 1.1 *Chương cất tri thức từ một mô hình thầy lớn hơn có thực sự giúp mô hình học trò nhỏ tốt hơn so với chính nó khi được huấn luyện thông thường, trong điều kiện bộ dữ liệu quy mô vừa?*

Câu hỏi nghiên cứu 1.2 *Lượng tử hoá sau huấn luyện đánh đổi những gì giữa dung lượng, tốc độ và độ chính xác, và cái giá đó phân bổ ra sao trên các nhóm vật thể có kích thước khác nhau?*

Câu hỏi nghiên cứu 1.3 *Chỉ số mAP tổng phản ánh đến mức nào năng lực thực sự của mô hình, và đặc điểm nào của bộ dữ liệu khiến chỉ số đó có nguy cơ gây hiểu nhầm?*

1.2 Mục tiêu đề tài

Đề tài hướng đến các mục tiêu chính sau:

- Xây dựng một quy trình thực nghiệm tái lập được, trong đó cả năm cấu hình khảo sát được huấn luyện và đánh giá trong *cùng một lượt chạy*, trên cùng một tập kiểm tra và cùng một bộ tính độ đo, để loại bỏ mọi khác biệt do môi trường.
- Đánh giá bằng pycocotools trên định dạng COCO nhằm thu được *AP* tách riêng theo nhóm kích thước vật thể, thay vì chỉ báo cáo mAP tổng.
- Khai báo trước các ngưỡng chấp nhận cho từng giả thuyết, và báo cáo đầy đủ cả những ngưỡng không đạt.

- Phân tích khám phá dữ liệu ở mức đủ sâu để giải thích được kết quả, bao gồm kiểm toán rõ ràng giữa các tập.
- Báo cáo trung thực các kết quả đi ngược giả thuyết ban đầu, kèm phân tích nguyên nhân và các yếu tố gây nhiễu chưa kiểm soát được.

1.3 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: hiệu quả của hai kỹ thuật nén mô hình — chưng cất tri thức và lượng tử hoá sau huấn luyện — áp dụng cho bộ phát hiện biển báo giao thông, xét đồng thời trên ba trục độ chính xác, tốc độ và dung lượng, trong đó độ chính xác được tách theo nhóm kích thước vật thể.

Phạm vi nghiên cứu: đề tài giới hạn ở bộ dữ liệu *pkdarabi/cardetection* với 15 lớp gốc, giữ nguyên không ánh xạ lại nhãn. Mô hình thầy là YOLO26s, mô hình học trò là YOLO26n, cả hai huấn luyện 50 chu kỳ ở kích thước ảnh 640. Lượng tử hoá được thực hiện qua đường xuất ONNX.

Đề tài *không* bao gồm: thu thập và gán nhãn dữ liệu mới, tìm kiếm siêu tham số tự động, quét hệ số chưng cất, khảo sát các kiến trúc phát hiện khác, và triển khai thực tế trên phần cứng nhúng. Những giới hạn này được nêu rõ ngay từ đầu vì chúng ảnh hưởng trực tiếp tới cách diễn giải kết quả ở Chương 4.

1.4 Đóng góp của đề tài

1. **Một thiết kế thực nghiệm có đối chứng đúng nghĩa.** Mô hình học trò được huấn luyện hai lần với cùng số chu kỳ, cùng hạt ngẫu nhiên, cùng kích thước ảnh — một lần thông thường và một lần có chưng cất — nên chênh lệch quan sát được quy về đúng biến số cần khảo sát. Kèm theo đó là năm ngưỡng chấp nhận khai báo trước khi chạy.
2. **Bằng chứng định lượng cho thấy mAP tổng che giấu chi phí thật của việc nén mô hình.** Lượng tử hoá INT8 làm mAP@0,5 giảm 0,0038 nhưng làm AP trên vật thể nhỏ giảm 0,0247 — gấp 6,5 lần. Đây là đóng góp chính của đề tài và nó có hệ quả thực tiễn trực tiếp: mọi quyết định chọn cấu hình triển khai chỉ dựa trên mAP tổng đều có nguy cơ sai.
3. **Một kết quả âm được báo cáo đầy đủ.** Chưng cất tri thức làm giảm độ chính xác so với đối chứng. Kết quả này được giữ lại kèm bằng chứng cho thấy cơ chế chưng

cắt đã thực sự hoạt động, và kèm phân tích các điều kiện khiến kỹ thuật không phát huy tác dụng.

4. **Một phân tích dữ liệu chỉ ra hai vấn đề của bộ dữ liệu công khai được dùng rộng rãi:** 38,68% số ảnh là ảnh cắt cận cảnh kiểu GTSRB [8] khiến phân bố kích thước bị lưỡng cực, và 10,2% tập kiểm tra có bản sao trong tập huấn luyện.

1.5 Bố cục báo cáo

Chương 1 giới thiệu tổng quan về bài toán, mục tiêu và phạm vi. Chương 2 trình bày cơ sở lý thuyết về phát hiện đối tượng một giai đoạn, hệ thống độ đo và hai kỹ thuật nén mô hình. Chương 3 mô tả bộ dữ liệu, kết quả phân tích khám phá và thiết kế thực nghiệm. Chương 4 trình bày và bàn luận kết quả, bao gồm phần phân tích lỗi và các kết quả trái với kỳ vọng. Chương 5 tổng kết, nêu hạn chế và hướng phát triển.

CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT VÀ CÔNG TRÌNH LIÊN QUAN

2.1 Bài toán phát hiện đối tượng

2.1.1 Phát biểu bài toán

Cho một ảnh $I \in \mathbb{R}^{H \times W \times 3}$, bài toán phát hiện đối tượng yêu cầu sinh ra một tập hợp

$$\mathcal{D} = \{(c_i, b_i, s_i)\}_{i=1}^N, \quad (2.1)$$

trong đó $c_i \in \{1, \dots, K\}$ là nhãn lớp, $b_i = (x_i, y_i, w_i, h_i)$ là hộp bao và $s_i \in [0, 1]$ là điểm tin cậy. Số lượng vật thể N không biết trước và thay đổi theo từng ảnh — đây chính là điểm khiến bài toán khó hơn phân lớp ảnh, nơi đầu ra luôn là một véc-tơ có kích thước cố định.

Lịch sử phát triển của lĩnh vực đi qua hai dòng lớn. Dòng hai giai đoạn, tiêu biểu là Faster R-CNN [9], tách bài toán thành bước đề xuất vùng rồi mới phân loại và tinh chỉnh hộp bao; độ chính xác cao nhưng chi phí tính toán lớn. Dòng một giai đoạn, khởi đầu từ YOLO [1] và SSD [10], dự đoán trực tiếp hộp bao và lớp trên bản đồ đặc trưng chỉ trong một lượt truyền xuôi, đổi một phần độ chính xác lấy tốc độ đủ cho ứng dụng thời gian thực. Đề tài này làm việc hoàn toàn trong dòng thứ hai.

2.1.2 Định dạng chú thích

Hai định dạng chú thích được dùng trong đề tài. Định dạng YOLO lưu mỗi vật thể trên một dòng văn bản gồm `class_id`, tâm hộp (x_c, y_c) và kích thước (w, h) , tất cả đã chuẩn hoá về đoạn $[0, 1]$ theo kích thước ảnh; đây là định dạng mà thư viện huấn luyện đọc trực tiếp. Định dạng COCO [11] dùng một tệp JSON duy nhất chứa ba khối `images`, `annotations` và `categories`, với hộp bao lưu theo góc trên trái và kích thước tuyệt đối tính bằng điểm ảnh.

Phép chuyển từ YOLO sang COCO là bước bắt buộc trong đề tài vì khâu đánh giá dùng `pycocotools`. Công thức chuyển đổi:

$$\begin{aligned} x_{\text{trái}} &= \left(x_c - \frac{w}{2}\right) \cdot W_{\text{ảnh}}, & y_{\text{trên}} &= \left(y_c - \frac{h}{2}\right) \cdot H_{\text{ảnh}}, \\ w_{\text{tuyệt đối}} &= w \cdot W_{\text{ảnh}}, & h_{\text{tuyệt đối}} &= h \cdot H_{\text{ảnh}}. \end{aligned} \quad (2.2)$$

Trường `area` bằng tích $w_{\text{tuyệt đối}} \cdot h_{\text{tuyệt đối}}$. Trường này không chỉ mang tính mô tả: bộ đánh

giá COCO dùng chính nó để phân nhóm vật thể thành nhỏ, trung bình và lớn khi tính AP theo kích thước — chỉ số trung tâm của đề tài này.

2.2 Bộ phát hiện một giai đoạn

2.2.1 Nguyên lý chung

Bộ phát hiện một giai đoạn bỏ hẳn bước đề xuất vùng. Ảnh đi qua một mạng xương sống tích chập để sinh bản đồ đặc trưng, sau đó một đầu dự đoán gắn trực tiếp lên bản đồ đó sẽ xuất ra hộp bao và điểm phân lớp cho từng vị trí. Vì toàn bộ quá trình chỉ cần một lượt truyền xuôi, tốc độ suy luận cao hơn đáng kể so với dòng hai giai đoạn [1].

Điểm yếu cố hữu của cách làm này là mất cân bằng cực đoan giữa số vị trí nền và số vị trí chứa vật thể. Focal Loss [12] giải quyết bằng cách giảm trọng số đóng góp của các mẫu dễ:

$$\mathcal{L}_{\text{focal}}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad (2.3)$$

trong đó p_t là xác suất mô hình gán cho lớp đúng và γ điều khiển mức độ giảm trọng số.

2.2.2 Đa tỉ lệ và vật thể nhỏ

Một biển báo cách xe 50 mét và một biển báo cách 5 mét có kích thước trên ảnh chênh nhau hàng chục lần. Mạng kim tự tháp đặc trưng (FPN) [13] xử lý điều này bằng cách kết hợp đặc trưng ở nhiều tầng phân giải: tầng nông giữ chi tiết không gian tốt cho vật thể nhỏ, tầng sâu giàu ngữ nghĩa hơn cho vật thể lớn.

Dù vậy, vật thể nhỏ vẫn là điểm yếu dai dẳng [5]. Nguyên nhân nằm ở bước sải: đầu dự đoán P3 hoạt động ở bước sải 8, nghĩa là một vật thể 16 điểm ảnh chỉ trải trên hai ô lưới. Tín hiệu mà một vật thể nhỏ để lại trên bản đồ đặc trưng vốn đã yếu, nên nó là thành phần *mong manh nhất* của toàn bộ hệ thống — và cũng là thành phần đầu tiên bị tổn hại khi ta can thiệp vào mô hình bằng các phép nén. Đây chính là lý do lý thuyết khiến đề tài đo AP tách theo nhóm kích thước thay vì chỉ đọc mAP tổng.

2.2.3 Hàm mất mát của họ YOLO hiện đại

Các phiên bản YOLO hiện đại [2] là bộ phát hiện không dùng hộp neo. Hàm mất mát tổng gồm ba thành phần:

$$\mathcal{L} = \lambda_{\text{box}} \mathcal{L}_{\text{CIoU}} + \lambda_{\text{cls}} \mathcal{L}_{\text{BCE}} + \lambda_{\text{dfl}} \mathcal{L}_{\text{DFL}}. \quad (2.4)$$

Thành phần thứ nhất dùng CIoU [14], một mở rộng của IoU có tính thêm khoảng

cách giữa hai tâm hộp và độ lệch tỉ lệ khung, nhờ đó vẫn cung cấp gradient hữu ích ngay cả khi hai hộp chưa giao nhau — trường hợp mà IoU thuần túy cho gradient bằng không. Thành phần thứ ba là Distribution Focal Loss [15], coi mỗi cạnh hộp bao là một phân phối rời rạc thay vì một giá trị điểm, giúp việc hồi quy biên ổn định hơn khi ranh giới vật thể mờ.

Khi bật chưng cất tri thức, một thành phần thứ tư được cộng thêm vào biểu thức (2.4) — chi tiết ở Mục 2.4.1.

Sau khi suy luận, bước hậu xử lý NMS loại bỏ các hộp trùng cho cùng một vật thể: các hộp được sắp theo điểm tin cậy giảm dần, hộp có điểm cao nhất được giữ lại và mọi hộp còn lại có IoU với nó vượt ngưỡng sẽ bị loại.

2.3 Hệ thống độ đo

2.3.1 IoU, Precision và Recall

Độ đo nền tảng là tỉ số giao trên hợp giữa hộp dự đoán B_p và hộp thật B_g :

$$\text{IoU}(B_p, B_g) = \frac{|B_p \cap B_g|}{|B_p \cup B_g|}. \quad (2.5)$$

Một dự đoán được tính là dương tính đúng khi lớp khớp và IoU vượt ngưỡng cho trước. Từ đó suy ra

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (2.6)$$

2.3.2 mAP

Sắp toàn bộ dự đoán theo điểm tin cậy giảm dần và tính cặp (Precision, Recall) tại từng ngưỡng cho ta đường cong PR. Độ chính xác trung bình AP là diện tích dưới đường cong này, và mAP là trung bình của AP trên toàn bộ các lớp. Cách định nghĩa này kế thừa từ bộ chuẩn PASCAL VOC [16] và được COCO [11] mở rộng thêm chiều ngưỡng IoU:

$$AP = \int_0^1 p(r) dr, \quad mAP = \frac{1}{K} \sum_{k=1}^K AP_k. \quad (2.7)$$

Quy ước COCO báo cáo hai biến thể: $mAP@0,5$ tính tại một ngưỡng IoU duy nhất là 0,5, và $mAP@0,5:0,95$ lấy trung bình trên mười ngưỡng từ 0,5 đến 0,95 với bước 0,05. Biến thể thứ hai khắt khe hơn nhiều vì nó đòi hỏi hộp bao phải khít, chứ không chỉ chồng lấn ở mức tối thiểu.

Một hệ quả quan trọng của việc mAP là độ đo *xếp hạng*: khi tính mAP , không được

lọc dự đoán theo ngưỡng tin cậy trước, vì làm vậy sẽ cắt mất phần đuôi của đường cong PR và bóp méo kết quả. Ngưỡng tin cậy chỉ nên áp dụng ở khâu hiển thị.

2.3.3 AP tách theo nhóm kích thước

Đây là công cụ trung tâm của đề tài, nên cần nói rõ vì sao nó cần thiết.

Biểu thức (2.7) lấy trung bình trên các lớp nhưng *không* phân biệt kích thước vật thể. Nếu tập đánh giá có nhiều vật thể lớn — vốn dễ phát hiện — thì AP cao trên nhóm này sẽ kéo mAP tổng lên và che lấp một suy giảm nghiêm trọng ở nhóm nhỏ. Hiện tượng pha loãng này càng nặng khi phân bố kích thước lệch, đúng như trường hợp bộ dữ liệu được dùng ở đây (xem Mục 3.1.4).

Bộ đánh giá COCO [11] khắc phục bằng cách tính AP riêng cho ba nhóm dựa trên diện tích tuyệt đối của hộp bao:

$$AP_{\text{nhỏ}} : a < 32^2, \quad AP_{\text{trung bình}} : 32^2 \leq a < 96^2, \quad AP_{\text{lớn}} : a \geq 96^2, \quad (2.8)$$

với a tính bằng điểm ảnh vuông. Ba chỉ số này cho phép trả lời câu hỏi mà mAP tổng không trả lời được: khi một phép can thiệp làm mô hình kém đi, *phần kém đó rơi vào nhóm nào*. Với bài toán biển báo giao thông, câu trả lời có ý nghĩa an toàn trực tiếp, vì biển ở xa — tức vật thể nhỏ — mới là thứ quyết định thời gian phản ứng của xe.

2.3.4 Độ đo chi phí triển khai

Ba đại lượng bổ sung được dùng để phản ánh ràng buộc thực tế: độ trễ suy luận tính bằng mili-giây cho mỗi ảnh, tốc độ khung hình bằng nghịch đảo của độ trễ, và dung lượng mô hình tính bằng megabyte. Ngoài giá trị trung vị, đề tài còn báo cáo phân vị 95% của độ trễ, vì với hệ thống thời gian thực thì trường hợp xấu nhất mới là ràng buộc thật chứ không phải trường hợp trung bình.

Cả ba đại lượng đều phụ thuộc phần cứng nên phải luôn báo cáo kèm thiết bị đo. Ngoài ra, do GPU thực thi bất đồng bộ, phép đo thời gian phải có bước đồng bộ hoá tường minh và một giai đoạn khởi động trước khi bấm giờ, nếu không sẽ ghi nhận sai thời gian tính toán thực.

2.4 Nén mô hình

2.4.1 Chứng cất tri thức

Chứng cất tri thức [3] huấn luyện một mô hình học trò nhỏ bắt chước phân phối đầu ra mềm của một mô hình thầy lớn hơn. Hàm mất mát kết hợp

$$\mathcal{L} = (1 - \alpha) \mathcal{L}_{\text{cứng}} + \alpha T^2 \mathcal{L}_{\text{KL}}(\sigma(z_s/T) \parallel \sigma(z_t/T)), \quad (2.9)$$

với T là nhiệt độ làm mềm phân phối và z_s, z_t là logit của học trò và thầy.

Trong bối cảnh phát hiện đối tượng, việc áp dụng chứng cất phức tạp hơn phân lớp ảnh vì đầu ra gồm cả thành phần hồi quy hộp bao lẫn thành phần phân loại, và vì mất cân bằng nền–vật thể rất lớn. Các công trình chuyên biệt đã đề xuất chứng cất trên đặc trưng trung gian thay vì chỉ trên logit [17, 18]; một khảo sát tổng quan về các biến thể có thể tìm thấy trong [19].

Giả thuyết nền là phân phối mềm của thầy mang cái thường được gọi là “tri thức tối”: thông tin về *quan hệ* giữa các lớp mà nhãn cứng không có. Chẳng hạn khi nhìn một biển “Speed Limit 30”, thầy có thể gán xác suất thứ hai cho “Speed Limit 80” — hàm ý rằng hai lớp này dễ nhầm — trong khi nhãn cứng chỉ nói lớp đúng là gì.

Tuy nhiên lợi ích này *không được bảo đảm*, và điều kiện áp dụng thường bị bỏ qua trong các trình bày phổ thông. Khi khoảng cách năng lực giữa thầy và trò quá nhỏ, lượng tri thức tối có thể truyền đạt là rất ít, trong khi chi phí nhiều do bắt chước một phân phối không hoàn hảo vẫn phải trả đủ. Khi bản thân thầy chưa đủ tốt, học trò đang bắt chước một tín hiệu sai. Và khi trọng số α quá lớn, thành phần bắt chước có thể lấn át tín hiệu từ nhãn cứng. Đề tài này quan sát được đúng một tình huống như vậy, trình bày ở Chương 4.

Trong bối cảnh phát hiện đối tượng, thành phần chứng cất được cộng thêm vào hàm mất mát tổng ở biểu thức (2.4) và xuất hiện trong nhật ký huấn luyện dưới dạng một cột riêng — chi tiết này về sau trở thành bằng chứng để xác minh cơ chế đã thực sự được kích hoạt.

2.4.2 Lượng tử hoá

Lượng tử hoá thay biểu diễn dấu phẩy động 32 bit bằng biểu diễn có độ rộng bit nhỏ hơn. Phép ánh xạ affine sang số nguyên 8 bit [4] có dạng

$$r \approx S(q - Z), \quad (2.10)$$

trong đó r là giá trị thực, q là giá trị nguyên, S là hệ số tỉ lệ và Z là điểm không. Các tham số S và Z được xác định ở bước *hiệu chuẩn*: chạy mô hình trên một tập ảnh đại diện để quan sát dải giá trị thực tế của các kích hoạt. Việc chọn dải này ảnh hưởng đáng kể tới chất lượng mô hình sau lượng tử hoá, và các hướng dẫn thực hành chi tiết có thể tìm thấy trong [20, 21]; một khảo sát tổng quan về các phương pháp lượng tử hoá được trình bày trong [22].

Lượng tử hoá sau huấn luyện hấp dẫn vì không cần huấn luyện lại. Cái giá là sai số lượng tử hoá: mỗi giá trị thực bị làm tròn về mức gần nhất trong 256 mức khả dĩ. Ở mức FP16, việc giảm độ rộng bit gần như không ảnh hưởng tới chất lượng mô hình trong nhiều tác vụ [23]. Ở mức INT8, mức nén mạnh hơn nhiều nhưng sai số cũng lớn hơn hẳn.

Có một dự đoán lý thuyết đáng chú ý ở đây, và nó được kiểm chứng ở Chương 4: vì sai số lượng tử hoá tác động lên toàn bộ bản đồ đặc trưng, còn vật thể nhỏ vốn chỉ để lại tín hiệu yếu trên bản đồ đó (Mục 2.2.2), *tỉ lệ tín hiệu trên nhiễu của vật thể nhỏ suy giảm nhiều hơn của vật thể lớn*. Nói cách khác, chi phí của lượng tử hoá được dự đoán là phân bố *không đều* theo kích thước vật thể — và đó chính là thứ mAP tổng không thể hiện được.

Ngoài ra, lợi ích về tốc độ của INT8 không tự động: nó chỉ hiện thực hoá khi môi trường thực thi có nhân tính toán số nguyên được tối ưu cho phần cứng đích. Nếu không, thời gian tiết kiệm được có thể bị tiêu hết vào các phép chuyển đổi lượng tử hoá và giải lượng tử hoá xen giữa các lớp.

2.5 Công trình liên quan về biển báo giao thông

GTSRB [8] là bộ chuẩn kinh điển cho *nhận dạng* biển báo, gồm các ảnh đã cắt sát quanh từng biển; đây là bài toán phân lớp chứ không phải phát hiện. GTSDb [24] bổ sung phần *phát hiện* với ảnh đường phố đầy đủ. TT100K [25] mở rộng quy mô sang bối cảnh Trung Quốc với ảnh toàn cảnh độ phân giải cao, còn Mapillary Traffic Sign [26] cung cấp dữ liệu đa quốc gia thu từ camera hành trình.

Phân biệt giữa bộ dữ liệu kiểu nhận dạng và bộ dữ liệu kiểu phát hiện có ý nghĩa trực tiếp với đề tài này: như sẽ trình bày ở Mục 3.1.4, bộ dữ liệu được dùng là một tập trộn chứa cả hai kiểu, và chính điều đó chi phối phân bố kích thước vật thể — yếu tố quyết định cách đọc mọi chỉ số về sau. Hiện tượng bộ dữ liệu mang thiên lệch đặc thù và mô hình học phải thiên lệch đó thay vì học đặc trưng tổng quát đã được chỉ ra từ lâu [27], còn việc chỉ số trên tập kiểm tra không chuyển được sang dữ liệu mới cũng đã được ghi nhận trên các bộ chuẩn lớn [28]. Riêng vấn đề trùng lặp gần giữa các tập, vốn làm chỉ số bị thổi phồng một cách âm

thâm, đã được khảo sát kỹ trên nhiều bộ chuẩn phổ biến [7].

CHƯƠNG 3 : DỮ LIỆU VÀ PHƯƠNG PHÁP

3.1 Bộ dữ liệu

3.1.1 Nguồn và quy mô

Đề tài sử dụng bộ dữ liệu *pkdarabi/cardetection* công bố trên Kaggle, phân phối dưới dạng một bản xuất Roboflow theo bố cục thư mục chuẩn $\{\text{train}, \text{valid}, \text{test}\} / \{\text{images}, \text{labels}\}$ với nhãn ở định dạng YOLO TXT. Mặc dù tên trên đường dẫn là “car detection”, nội dung thực tế của toàn bộ 15 lớp đều là đèn tín hiệu và biển giới hạn tốc độ, không có lớp nào là phương tiện. Nhóm thực hiện giữ nguyên 15 lớp gốc, không gộp cũng không ánh xạ lại nhãn, để kết quả có thể đối chiếu với các công bố khác dùng cùng bộ dữ liệu.


Bảng 3.1. Thống kê tổng quan bộ dữ liệu theo từng tập

Tập	Số ảnh	Tỉ lệ	Số hộp bao	Hộp/ảnh
Huấn luyện	3.530	71,0%	4.298	1,218
Kiểm định	801	16,1%	944	1,179
Kiểm tra	638	12,8%	770	1,207
Tổng	4.969	100%	6.012	1,210

Toàn bộ ảnh có độ phân giải đồng nhất 416×416 điểm ảnh — hệ quả của bước tiền xử lý mà Roboflow áp dụng khi xuất bộ dữ liệu. Chi tiết này có một hệ quả kỹ thuật đáng lưu ý: việc tăng kích thước ảnh đầu vào khi huấn luyện chủ yếu là phóng to chứ không bổ sung thêm chi tiết thật.

Mật độ vật thể rất thưa: trung bình chỉ 1,21 hộp bao trên mỗi ảnh, cao nhất là 10 hộp ở tập kiểm tra. Đây là đặc điểm khác hẳn các bộ dữ liệu cảnh đường phố như TT100K [25], nơi một khung hình có thể chứa hàng chục biển báo.

3.1.2 Phân bố lớp và mất cân bằng



Hình 3.1. Phân bố số hộp bao theo từng lớp trên toàn bộ dữ liệu


Hình 3.1 và Bảng 3.2 cho thấy mức mất cân bằng đáng kể. Hai lớp đèn tín hiệu chiếm gần 26% tổng số hộp bao, trong khi lớp *Speed Limit 10* chỉ có 22 mẫu, tương đương 0,37%. Tỷ số mất cân bằng, định nghĩa bằng thương giữa số mẫu của lớp nhiều nhất và lớp ít nhất, đạt **35,77**.

Bảng 3.2. Phân bố lớp chi tiết, sắp theo số hộp bao giảm dần

Mã lớp	Tên lớp	Số hộp	Tỉ lệ (%)	Tỉ số so với lớp lớn nhất
1	Red Light	787	13,09	1,00
0	Green Light	774	12,87	1,02
7	Speed Limit 30	468	7,78	1,68
11	Speed Limit 70	449	7,47	1,75
12	Speed Limit 80	440	7,32	1,79
10	Speed Limit 60	422	7,02	1,86
14	Stop	416	6,92	1,89
9	Speed Limit 50	404	6,72	1,95
6	Speed Limit 20	387	6,44	2,03
3	Speed Limit 100	365	6,07	2,16
5	Speed Limit 120	356	5,92	2,21
8	Speed Limit 40	343	5,71	2,29
13	Speed Limit 90	240	3,99	3,28
4	Speed Limit 110	139	2,31	5,66
2	Speed Limit 10	22	0,37	35,77

Khi cài đặt phép tính này, một chi tiết dễ sai đã được xử lý tường minh: nếu chỉ đếm các lớp thực sự xuất hiện trong dữ liệu, một lớp được khai báo trong tệp cấu hình nhưng không có mẫu nào sẽ bị âm thầm bỏ qua, khiến tỉ số mất cân bằng bị báo cáo thấp hơn thực tế và “lớp hiếm nhất” bị xác định sai. Mô-đun phân tích do đó đánh chỉ mục lại bảng đếm theo toàn bộ tập lớp khai báo với giá trị mặc định bằng không, và trả về vô cùng khi có lớp rỗng.

3.1.3 Thống kê kích thước hộp bao



Hình 3.2. Thống kê kích thước hộp bao trên toàn bộ dữ liệu

Việc phân nhóm kích thước ở bước khám phá dữ liệu dùng diện tích đã chuẩn hoá $a = w \cdot h$ với $w, h \in [0, 1]$, theo ba ngưỡng: nhỏ khi $a < 0,01$, trung bình khi $0,01 \leq a < 0,05$, và lớn trong các trường hợp còn lại. Cần lưu ý rằng quy ước này khác với quy ước COCO ở biểu thức (2.8), vốn dùng diện tích tuyệt đối theo điểm ảnh. Lựa chọn dùng diện tích chuẩn hoá ở đây là có chủ ý: nó độc lập với độ phân giải ảnh nên so sánh được giữa các nguồn dữ liệu khác nhau. Khi tính AP ở Chương 4 thì quy ước COCO được dùng.

Bảng 3.3. Phân nhóm kích thước hộp bao theo diện tích chuẩn hoá

Nhóm	Số hộp	Tỉ lệ (%)	Ngưỡng diện tích chuẩn hoá
Nhỏ	2.122	35,30	$a < 0,01$
Trung bình	806	13,41	$0,01 \leq a < 0,05$
Lớn	3.084	51,30	$a \geq 0,05$

Bảng 3.3 chứa một tín hiệu bất thường. Trong một bộ dữ liệu cảnh đường phố thông thường, nhóm vật thể lớn hiếm khi chiếm quá bán, bởi biển báo chiếm hơn 5% diện tích khung hình đồng nghĩa với việc xe đã ở rất gần biển. Ở đây nhóm lớn chiếm tới 51,30%. Điều này thúc đẩy phân tích ở mục tiếp theo.

3.1.4 Phân tích thành phần bộ dữ liệu

Quan sát tên tệp cho thấy bộ dữ liệu không đồng nhất mà là một tập *trộn* từ nhiều nguồn có quy ước đặt tên khác nhau. Nhóm thực hiện phân loại ảnh theo mẫu tên tệp và tính lại thống kê kích thước riêng cho từng nhóm; kết quả trình bày ở Bảng 3.4.

Bảng 3.4. Thành phần bộ dữ liệu theo nguồn gốc suy ra từ quy ước đặt tên tệp

Nhóm nguồn	Số ảnh	Tỉ lệ (%)	Cạnh biển (trung vị)	% vật thể nhỏ
Ảnh cắt kiểu GTSRB	1.922	38,68	66,8% cạnh ảnh	0,0
Ảnh số sáu chữ số	1.586	31,92	19,6%	34,7
Ảnh cảnh đường	724	14,57	13,4%	31,1
Camera mắt cá	645	12,98	1,6%	99,6
Nhóm khác	92	1,85	75,7%	0,0

Kết quả này giải thích trọn vẹn hình dạng bất thường ở Bảng 3.3. Nhóm ảnh cắt kiểu GTSRB chiếm 38,68% số ảnh và có biển báo lắp gần kín khung hình — đây vốn là ảnh dành cho bài toán *phân lớp* chứ không phải *phát hiện* [8]. Ở đầu kia của thang đo, nhóm camera mắt cá có tới 99,6% vật thể thuộc nhóm nhỏ, với cạnh biển trung vị chỉ 1,6% cạnh ảnh, đồng thời mang hình học quang học hoàn toàn khác.

Hệ quả là phân bố kích thước bị *lưỡng cực*. Bảng 3.5 trình bày các phân vị diện tích quy đổi ra cạnh tính bằng điểm ảnh trên ảnh 416×416 .

Bảng 3.5. Phân vị diện tích hộp bao và cạnh tương ứng trên ảnh 416×416


Phân vị	10%	25%	50%	75%	90%
Diện tích chuẩn hoá	0,0003	0,0025	0,0570	0,3854	0,5402
Cạnh tương ứng (điểm ảnh)	6,9	20,8	99,3	258,2	305,8

Khoảng cách giữa phân vị 25% (20,8 điểm ảnh) và phân vị 75% (258,2 điểm ảnh) là hơn mười hai lần, và vùng “biển báo thật trên đường” — khoảng 30 đến 80 điểm ảnh — gần như trống. Đây là một dạng thiên lệch bộ dữ liệu điển hình [27], và nó có hai hệ quả đối với đề tài này. Thứ nhất, hơn một nửa vật thể thuộc nhóm lớn nên mAP tổng bị chi phối bởi các trường hợp dễ. Thứ hai, chính vì vậy mà việc tách *AP* theo nhóm kích thước như đã lập luận ở Mục 2.3.3 trở thành bắt buộc chứ không phải tùy chọn.



Hình 3.3. Ba chế độ ảnh cùng tồn tại trong bộ dữ liệu, kèm hộp bao nhãn thật

3.1.5 Vị trí vật thể trong khung hình



Hình 3.4. Bản đồ nhiệt vị trí tâm vật thể trên toàn bộ dữ liệu

Bản đồ nhiệt ở Hình 3.4 được xây bằng biểu đồ tần suất hai chiều trên tọa độ tâm đã chuẩn hoá. Hai chi tiết cài đặt cần lưu ý. Thứ nhất, trục tung được lật theo phép $y' = 1 - y_c$ vì hệ tọa độ ảnh đặt gốc ở góc trên trái với trục y hướng xuống, trong khi hệ tọa độ đồ thị hướng lên. Thứ hai, ma trận tần suất phải được chuyển vị trước khi hiển thị, do hàm dựng biểu đồ hai

chiều trả về theo thứ tự (trục hoành, trục tung) còn hàm hiển thị ảnh yêu cầu thứ tự (hàng, cột). Bỏ qua một trong hai bước này sẽ cho một bản đồ nhiệt trông hợp lý nhưng sai hoàn toàn về mặt hình học.

Điểm nóng tập trung mạnh ở vùng trung tâm, phản ánh đúng thành phần dữ liệu đã phân tích ở Mục 3.1.4: nhóm ảnh cắt kiểu GTSRB luôn đặt biển báo ở giữa khung hình.

3.1.6 Kiểm tra chất lượng nhãn

Một mô-đun kiểm tra độc lập rà soát tám loại lỗi: thiếu ảnh, thiếu nhãn, nhãn rỗng, ảnh hỏng, trùng tên ảnh giữa các tập, mã lớp ngoài miền hợp lệ, tọa độ hộp nằm ngoài đoạn $[0, 1]$ và hộp có cạnh bằng không.

Kết quả trên cả ba tập đều sạch về mặt hình học: không có hộp suy biến, không có mã lớp sai. Chỉ ghi nhận **4 ảnh có tệp nhãn rỗng**, tức ảnh nền không chứa biển báo nào — đây không phải lỗi mà là ảnh nền hợp lệ, thường được giữ lại có chủ đích để giảm dương tính giả.

Về mặt cài đặt, việc đối chiếu tên ảnh với tên tệp nhãn dùng cấu trúc tập hợp thay vì danh sách, nhờ đó phép kiểm tra thành viên có độ phức tạp hằng số thay vì tuyến tính, tránh chi phí bậc hai khi quy mô dữ liệu tăng.

3.1.7 Kiểm toán rò rỉ dữ liệu giữa các tập

Một thủ tục kiểm toán riêng được thực hiện để phát hiện ảnh xuất hiện ở nhiều hơn một tập — vấn đề đã được ghi nhận là nguồn thổi phồng chỉ số trên nhiều bộ chuẩn phổ biến [7]. Thủ tục đối chiếu theo hai mức: tên ảnh nguồn sau khi loại bỏ hậu tố ngẫu nhiên do Roboflow thêm vào, và băm nội dung tệp để xác định các cặp trùng byte hoàn toàn. Kết quả được trình bày ở Mục 4.2.2 và ảnh hưởng trực tiếp tới cách diễn giải mọi chỉ số trong báo cáo.

3.2 Thiết kế thực nghiệm

3.2.1 Năm cấu hình khảo sát

Toàn bộ thực nghiệm được tổ chức thành một lượt chạy duy nhất sinh ra năm cấu hình, trình bày ở Bảng 3.6. Việc gộp chung một lượt là có chủ đích: nó bảo đảm mọi cấu hình dùng cùng một tập kiểm tra, cùng một phần cứng và cùng một bộ tính độ đo, nên chênh lệch quan sát được không lẫn yếu tố môi trường.

Bảng 3.6. Năm cấu hình khảo sát và vai trò của từng cấu hình

Cấu hình	Vai trò	Mục đích
YOLO26s	Thầy	Cung cấp phân phối mềm cho chứng cất; đồng thời là cận trên tham chiếu
YOLO26n	Trò đối chứng	Huấn luyện thông thường — mốc so sánh cho giả thuyết chứng cất
YOLO26n + chứng cất	Trò chứng cất	Cấu hình cần đánh giá của giả thuyết thứ nhất
ONNX FP32	Xuất từ trò chứng cất	Tách riêng ảnh hưởng của việc đổi môi trường thực thi
ONNX INT8	Xuất từ trò chứng cất	Cấu hình cần đánh giá của giả thuyết thứ hai

Cần chú ý vai trò của cấu hình ONNX FP32: nó tồn tại để *cô lập biến số*. Nếu chỉ so ONNX INT8 với mô hình PyTorch gốc, phần chênh lệch sẽ trộn lẫn hai nguyên nhân — đổi môi trường thực thi và lượng tử hoá. Có thêm mốc ONNX FP32 ở giữa cho phép quy phần chênh lệch giữa hai bản ONNX về đúng tác động của lượng tử hoá.

3.2.2 Siêu tham số

Bảng 3.7. Siêu tham số huấn luyện và đánh giá

Tham số	Giá trị	Ghi chú
Mô hình thầy	yo1o26s.pt	9,47 triệu tham số
Mô hình trò	yo1o26n.pt	2,38 triệu tham số
Số chu kỳ	50 / 50 / 50	Thầy, trò đối chứng, trò chứng cất — bằng nhau
Kích thước lô	16 / 24 / 8	Không bằng nhau — xem ghi chú bên dưới
Kiên nhẫn dừng sớm	12	
Hệ số chứng cất	6,0	Giá trị mặc định của thư viện
Kích thước ảnh	640	
Hạt ngẫu nhiên	42	Dùng chung cho toàn bộ đề tài
Ngưỡng tin cậy khi đo	0,001	Gần bằng không, phù hợp với độ đo xếp hạng
Ngưỡng IoU khi khớp	0,50	
Số ảnh hiệu chuẩn INT8	300	
Số lượt khởi động / đo tốc độ	10 / 100	

Cả ba nhánh huấn luyện đều dùng bộ tăng cường dữ liệu mặc định của thư viện, trong đó có phép ghép ảnh mosaic phổ biến từ YOLOv4 [29] — kỹ thuật ghép bốn ảnh thành một, vừa tăng số ngữ cảnh nền mà mỗi vật thể xuất hiện, vừa tạo ra các vật thể ở tỉ lệ nhỏ hơn. Việc giữ nguyên cùng một bộ tăng cường cho cả ba nhánh là điều kiện cần để so sánh công bằng; nói chung, tăng cường dữ liệu phải phù hợp với ngữ nghĩa của miền ứng dụng chứ không thể áp dụng máy móc [30].

Mô hình trò được huấn luyện *hai lần* với cùng số chu kỳ, cùng hạt ngẫu nhiên và cùng kích thước ảnh — một lần thông thường và một lần bật chứng cất. Đây là điều kiện cần để chênh lệch quan sát được quy về đúng biến số cần khảo sát.

Tuy nhiên cần nêu rõ một **yếu tố gây nhiễu chưa kiểm soát được**: nhánh chứng cất chạy với kích thước lô bằng 8, trong khi nhánh đối chứng dùng 24. Nguyên nhân là trong quá trình chứng cất phải nạp đồng thời cả mô hình thầy lẫn mô hình trò vào bộ nhớ card đồ họa. Vì kích thước lô ảnh hưởng tới chất lượng ước lượng gradient, phần chênh lệch quan sát được ở Chương 4 không thể quy hoàn toàn cho bản thân kỹ thuật chứng cất. Đây là hạn chế được ghi nhận thay vì bỏ qua.

3.2.3 Ngưỡng chấp nhận khai báo trước

Năm ngưỡng chấp nhận được khai báo *trước* khi chạy thực nghiệm, ngay trong ô cấu hình đầu tiên của sổ tay:

- Mô hình chứng cất không được kém mô hình đối chứng quá 0,005 điểm mAP@0,5:0,95.
- Mô hình chứng cất được kỳ vọng *tốt hơn* mô hình đối chứng.
- Bản INT8 không được giảm quá 0,015 điểm mAP so với bản FP32.
- Bản INT8 phải nhỏ hơn bản FP32 ít nhất 50% về dung lượng tệp.
- Mô hình trò phải nhẹ hơn mô hình thầy.

Cách làm này buộc người thực hiện cam kết tiêu chí đánh giá trước khi nhìn thấy số liệu, tránh việc điều chỉnh kỳ vọng cho khớp với kết quả thu được. Kết quả kiểm tra được báo cáo đầy đủ ở Chương 4, kể cả các ngưỡng không đạt.

3.2.4 Quy trình đánh giá

Toàn bộ năm cấu hình được đánh giá trên tập kiểm tra tách biệt bằng **pycocotools**, sau khi nhãn YOLO được chuyển sang định dạng COCO theo biểu thức (2.2). Lựa chọn này quan

trọng vì hai lý do. Thứ nhất, nó cho AP tách theo ba nhóm kích thước theo quy ước ở biểu thức (2.8) — chỉ số trung tâm của đề tài. Thứ hai, dùng một bộ đánh giá duy nhất cho cả mô hình PyTorch lẫn mô hình ONNX loại bỏ khả năng chênh lệch đến từ hai cài đặt mAP khác nhau.

Ngưỡng tin cậy khi đo được đặt bằng 0,001, tức gần như không lọc. Đây là điểm dễ gây hiểu nhầm nên cần nói rõ: mAP là độ đo xếp hạng, cần trọn bộ dự đoán có điểm số để dựng đầy đủ đường cong PR. Lọc theo ngưỡng tin cậy trước khi tính sẽ cắt mất phần đuôi độ bao phủ và làm sai lệch chỉ số. Ngưỡng tin cậy cao hơn chỉ được dùng ở khâu trình diễn trực quan.

Tốc độ suy luận được đo bằng cách chạy 100 lượt truyền xuôi sau 10 lượt khởi động, rồi lấy trung vị và phân vị 95%. Giai đoạn khởi động là bắt buộc vì lượt chạy đầu tiên chịu chi phí khởi tạo ngữ cảnh tính toán và dò thuật toán, sẽ làm phồng số đo nếu không loại bỏ.

3.2.5 Bảo đảm tính tái lập

Ba biện pháp được áp dụng. Thứ nhất, một hàm gieo hạt duy nhất đặt hạt cho biến môi trường băm của Python, thư viện ngẫu nhiên chuẩn, NumPy, PyTorch [31] và PyTorch CUDA, đồng thời bật chế độ tắt định của cuDNN và *tắt* chế độ tự dò thuật toán nhanh nhất. Việc tắt chế độ tự dò là cần thiết vì nó chọn thuật toán tích chập theo điều kiện thực thi tại thời điểm chạy, khiến kết quả không lặp lại được giữa các lần. Hạt mặc định là 42.

Thứ hai, mọi đường dẫn đầu vào và đầu ra được khai báo tại một nơi duy nhất, có hỗ trợ biến môi trường để cùng một mã nguồn chạy được trên nhiều nền tảng.

Ngoài ra, bộ tối ưu và lịch tốc độ học được giữ ở cấu hình mặc định của thư viện cho cả ba nhánh; họ thuật toán Adam có tách rời suy giảm trọng số [32] là lựa chọn tiêu chuẩn trong bối cảnh này.

Thứ ba, quy trình được chia thành các giai đoạn có đánh dấu hoàn thành, cho phép chạy lại từng phần mà không phải huấn luyện lại từ đầu — hữu ích khi phiên làm việc bị ngắt giữa chừng.

CHƯƠNG 4 : KẾT QUẢ VÀ BÀN LUẬN

4.1 Kết quả tổng quan

Bảng 4.1 tập hợp kết quả của cả năm cấu hình, đo bằng pycocotools trên cùng một tập kiểm tra gồm 638 ảnh, trong cùng một lượt chạy.

Bảng 4.1. Kết quả năm cấu hình đo bằng pycocotools trên tập kiểm tra

Cấu hình	Tham số (M)	Tệp (MB)	mAP@0,5	mAP@.5:.95	AP nhỏ	AP lớn	FPS
YOLO26s (thầy)	9,47	19,39	0,9520	0,7822	0,616	0,859	74,4
YOLO26n đối chứng	2,38	5,15	0,9348	0,7773	0,548	0,862	69,7
YOLO26n chưng cất	2,38	5,15	0,9014	0,7450	0,486	0,852	74,8
ONNX FP32 (từ trò KD)	—	9,35	0,9079	0,7473	0,462	0,847	19,8
ONNX INT8 (từ trò KD)	—	2,78	0,9041	0,7437	0,437	0,839	9,4

Nhận xét. Đọc theo cột mAP@0,5, khoảng cách giữa các cấu hình trông khiêm tốn — toàn bộ nằm trong dải 0,90 đến 0,95. Đọc theo cột AP nhỏ, bức tranh khác hẳn: dải trải từ 0,437 đến 0,616, tức chênh lệch tương đối lớn gấp nhiều lần. Đây là luận điểm trung tâm của báo cáo và sẽ được định lượng ở Mục 4.3.2.

Cột AP lớn cho thấy điều ngược lại: cả ba mô hình PyTorch đều nằm quanh mức 0,85–0,86, gần như không phân biệt được, và hai bản ONNX cũng chỉ thấp hơn chút ít. Nói cách khác, với vật thể lớn thì bài toán đã bão hoà và mọi cấu hình đều giải quyết tốt như nhau. Điều này nhất quán với phân tích thành phần bộ dữ liệu ở Mục 3.1.4: hơn một nửa số hộp bao thuộc nhóm lớn, và chính vì vậy chúng chi phối mAP tổng đồng thời che lấp mọi khác biệt thật sự.

4.2 Chưng cất tri thức

4.2.1 Xác minh cơ chế đã được kích hoạt

Trước khi diễn giải một kết quả âm, cần loại trừ khả năng cơ chế chưng cất không hề chạy — nếu không, ta chỉ đang so sánh hai lần huấn luyện thông thường với kích thước lô khác nhau.

Nhật ký huấn luyện của nhánh chưng cất có thêm cột `train/dis_loss`, cột này *không* tồn tại ở nhánh đối chứng. Giá trị của nó giảm từ **12,1663** ở chu kỳ đầu xuống **1,1608**

ở chu kỳ cuối. Vậy hàm mất mát chứng cất đã hoạt động và đã hội tụ; kết quả âm dưới đây là kết quả thật chứ không phải lỗi cấu hình.

4.2.2 Kết quả trái với kỳ vọng

Giả thuyết ban đầu là mô hình học trò sẽ hưởng lợi từ phân phối đầu ra mềm của mô hình thầy [3]. Kết quả ngược lại: mô hình được chứng cất đạt $mAP@0,5$ bằng 0,9014, thấp hơn mô hình đối chứng (0,9348) **3,34 điểm phần trăm**, và thấp hơn tới **6,20 điểm phần trăm** nếu xét riêng AP trên vật thể nhỏ.

Bảng 4.2. Ba phép so sánh cốt lõi

Phép so sánh	$\Delta mAP@0,5$	$\Delta mAP@.5:.95$	ΔAP nhỏ
Trò chứng cất so với trò đối chứng	-0,0334	-0,0323	-0,0620
Trò chứng cất so với thầy	-0,0507	-0,0372	-0,1308
ONNX INT8 so với ONNX FP32	-0,0038	-0,0036	-0,0247

Có ba cách giải thích khả dĩ cho kết quả này.

Thứ nhất, khoảng cách năng lực giữa thầy và trò quá hẹp. Thầy chỉ đạt 0,9520, tức nhỉnh hơn trò đối chứng 1,72 điểm phần trăm. Lượng “tri thức tối” mà một mô hình chỉ tốt hơn chút ít có thể truyền đạt là rất nhỏ, trong khi chi phí nhiều do bắt buộc một phân phối không hoàn hảo thì vẫn phải trả đủ. Đây đúng là điều kiện áp dụng đã nêu ở Mục 2.4.1.

Thứ hai, kích thước lô không đồng nhất. Nhánh chứng cất chạy với lô 8 so với 24 của nhánh đối chứng, do phải nạp đồng thời cả hai mô hình vào bộ nhớ card đồ họa. Đây là yếu tố gây nhiễu chưa kiểm soát được và tự nó đã đủ giải thích một phần chênh lệch. Cần nói thẳng rằng vì yếu tố này, kết luận “chứng cất có hại” *không* được rút ra một cách chắc chắn; điều rút ra được là “trong cấu hình cụ thể này, chứng cất không mang lại lợi ích”.

Thứ ba, hệ số chứng cất có thể quá lớn. Giá trị 6,0 là mặc định của thư viện, chưa được quét thử. Với một cặp thầy–trò gần nhau như vậy, thành phần bắt buộc có thể đã lấn át tín hiệu từ nhãn cứng.

4.2.3 Kiểm tra ngưỡng chấp nhận

Năm ngưỡng khai báo trước ở Mục 3.2.3 cho kết quả ba đạt, hai không đạt — và cả hai ngưỡng không đạt đều thuộc về giả thuyết chứng cất.

Bảng 4.3. Kiểm tra các ngưỡng chấp nhận khai báo trước khi chạy thực nghiệm

Ngưỡng	Giá trị đo	Kết quả
KD không kém đối chứng quá 0,005 điểm	$\Delta = -0,0323$	KHÔNG ĐẠT
KD tốt hơn đối chứng (kỳ vọng ban đầu)	$\Delta = -0,0323$	KHÔNG ĐẠT
INT8 giảm không quá 0,015 điểm so với FP32	giảm 0,0036	ĐẠT
INT8 nhỏ hơn FP32 ít nhất 50%	giảm 70,3%	ĐẠT
Trò chứng cất nhẹ hơn thầy	5,15 so với 19,39 MB	ĐẠT

Việc khai báo tiêu chí trước và báo cáo cả kết quả không đạt là cách làm đúng đắn về mặt phương pháp: nó ngăn việc diễn giải lại kỳ vọng sau khi đã nhìn thấy số liệu. Kết quả âm này được giữ lại thay vì loại bỏ, vì nó xác định rõ *điều kiện áp dụng* của kỹ thuật.

4.3 Lượng tử hoá

4.3.1 Đánh đổi giữa dung lượng, tốc độ và độ chính xác

Bảng 4.4. Ảnh hưởng của việc xuất mô hình và lượng tử hoá

Cấu hình	Tệp (MB)	mAP@0,5	Trung vị (ms)	p95 (ms)
PyTorch FP16 (gốc)	5,15	0,9014	13,37	14,33
ONNX FP32	9,35	0,9079	50,41	55,76
ONNX INT8	2,78	0,9041	106,90	112,88

Về dung lượng, lượng tử hoá đạt đúng mục tiêu: 2,78 MB so với 9,35 MB, tức giảm **70,3%**, vượt xa ngưỡng 50% đã đặt ra.

Về tốc độ thì kết quả trái ngược hoàn toàn với kỳ vọng thông thường. Về lý thuyết, biểu diễn số nguyên 8 bit cho phép dùng các nhân tính toán số nguyên nhanh hơn [4]. Trên thực tế, bản INT8 có độ trễ trung vị 106,90 ms, tức *chậm hơn* bản FP32 hơn hai lần và chậm hơn bản PyTorch gốc tới tám lần. Đúng như đã dự đoán ở Mục 2.4.2, lợi ích tốc độ của lượng tử hoá chỉ hiện thực hoá khi môi trường thực thi có nhân số nguyên được tối ưu cho phần cứng đích; nếu không, thời gian tiết kiệm được bị tiêu hết vào các phép chuyển đổi lượng tử hoá và giải lượng tử hoá xen giữa các lớp.

Cũng đáng lưu ý rằng bản ONNX FP32 đã chậm hơn bản PyTorch gốc gần bốn lần trước khi lượng tử hoá — đây là chi phí của việc đổi môi trường thực thi, và chính nhờ có

mốc trung gian này mà ta tách được hai nguyên nhân ra khỏi nhau.

4.3.2 Chi phí thật nằm ở vật thể nhỏ

Đây là kết quả quan trọng nhất của đề tài.

Nếu chỉ đọc mAP tổng, lượng tử hoá INT8 trông gần như miễn phí: mAP@0,5 giảm 0,0038, tức chưa tới nửa điểm phần trăm, đổi lại dung lượng giảm hơn 70%. Bất kỳ ai ra quyết định triển khai dựa trên con số đó sẽ kết luận rằng INT8 là lựa chọn hiển nhiên.

Nhưng khi tách theo nhóm kích thước, AP trên vật thể nhỏ giảm 0,0247 — **gấp 6,5 lần** mức suy giảm của mAP tổng.

Bảng 4.5. So sánh mức suy giảm giữa mAP tổng và AP trên vật thể nhỏ

Phép can thiệp	Δ mAP@0,5	Δ AP nhỏ	Tỉ số
Chung cất tri thức	-0,0334	-0,0620	1,9 lần
Lượng tử hoá INT8	-0,0038	-0,0247	6,5 lần


Nhận xét. Ở cả hai phép can thiệp, mức suy giảm trên vật thể nhỏ đều lớn hơn hẳn mức suy giảm trên mAP tổng. Hệ quả thực tiễn rất cụ thể: với bài toán biển báo giao thông, nơi biển ở xa quyết định thời gian phản ứng của xe, một quyết định triển khai chỉ dựa trên mAP tổng có nguy cơ sai nghiêm trọng. Phải đọc AP tách theo nhóm kích thước.

Cơ chế đằng sau hiện tượng này đã được dự đoán từ lý thuyết ở Mục 2.4.2: sai số lượng tử hoá tác động lên toàn bộ bản đồ đặc trưng, trong khi vật thể nhỏ vốn chỉ để lại tín hiệu yếu trên bản đồ đó, nên tỉ lệ tín hiệu trên nhiễu của chúng suy giảm nhiều hơn. Việc quan sát thực nghiệm khớp với dự đoán lý thuyết làm tăng độ tin cậy của kết luận.

Lý do mAP tổng che giấu được điều này cũng đã rõ từ Chương 3: 51,30% số hộp bao trong bộ dữ liệu thuộc nhóm lớn, và AP trên nhóm đó gần như không đổi (0,847 so với 0,839). Nhóm dễ chiếm đa số nên nó chi phối giá trị trung bình và pha loãng suy giảm ở nhóm khó.

4.4 Phân tích lỗi

4.4.1 Nhầm lẫn giữa các lớp



Hình 4.1. Ma trận nhầm lẫn chuẩn hoá trên tập kiểm định

Ma trận nhầm lẫn ở Hình 4.1 cho thấy đường chéo chính chiếm ưu thế rõ rệt. Các nhầm lẫn còn lại tập trung vào nhóm biển giới hạn tốc độ. Điều này hợp lý về mặt thị giác: mười ba lớp giới hạn tốc độ có hình dạng, màu sắc và viền hoàn toàn giống nhau, chỉ khác ở chữ số bên trong. Ở độ phân giải thấp, chữ số là chi tiết đầu tiên bị mất, trong khi hình tròn viền đỏ vẫn nhận ra được. Nói cách khác, mô hình *định vị* tốt hơn *phân loại*.

Quan sát này củng cố thêm cho kết luận ở Mục 4.3.2: khi vật thể nhỏ đi hoặc khi biểu diễn bị nhiễu do lượng tử hoá, phần thông tin mất đầu tiên chính là chi tiết nhỏ bên trong

biển — thứ quyết định phân loại đúng hay sai.

4.4.2 Ảnh hưởng của mất cân bằng lớp

Lớp *Speed Limit 10* chỉ có 22 mẫu trên toàn bộ dữ liệu, tương đương khoảng 15 mẫu trong tập huấn luyện. Với số lượng này, mô hình khó học được biểu diễn ổn định, và bất kỳ chỉ số nào tính riêng cho lớp đó đều có phương sai rất lớn. Đây là biểu hiện điển hình của bài toán mất cân bằng lớp trong học sâu [6].

Cần lưu ý rằng mAP lấy trung bình *không có trọng số* trên các lớp, nên một lớp thiếu số có *AP* thấp sẽ kéo mAP tổng xuống ngang bằng với một lớp đa số.

4.4.3 Rò rỉ dữ liệu giữa các tập

Thủ tục kiểm toán mô tả ở Mục 3.1.7 cho kết quả đáng lo ngại.

Bảng 4.6. Kết quả kiểm toán rò rỉ dữ liệu giữa các tập

Hạng mục	Số lượng
Nhóm ảnh nguồn xuất hiện ở nhiều hơn một tập	155
Trong đó trùng byte hoàn toàn	101
Ảnh kiểm tra có bản sao trong tập huấn luyện	65 / 638 (10,2%)
Tập kiểm tra thực sự sạch còn lại	573 ảnh

Mô hình đã nhìn thấy đúng 65 ảnh đó trong lúc huấn luyện, nên phần dự đoán trên chúng thiên về ghi nhớ hơn là khái quát hoá. Mọi con số mAP trong báo cáo này vì vậy nên được hiểu là *cận trên*.

Điểm nhẹ nhõm duy nhất: vì rò rỉ ảnh hưởng *như nhau* tới cả năm cấu hình — chúng dùng chung một tập kiểm tra — nên các phép so sánh tương đối ở Bảng 4.2 vẫn giữ nguyên giá trị. Cái bị ảnh hưởng là giá trị tuyệt đối, không phải thứ tự xếp hạng.

4.5 Kiểm chứng trên video đường thật

Toàn bộ kết quả ở các mục trên được đo trên tập kiểm tra, vốn có cùng phân bố với tập huấn luyện. Mục này kiểm chứng luận điểm trung tâm — rằng điểm yếu thật nằm ở vật thể nhỏ — trên dữ liệu *ngoài phân bố*: ba đoạn video đường phố thu bằng camera hành trình.

4.5.1 Thiết kế phép kiểm chứng

Bảng 4.7. Ba video dùng để kiểm chứng

Tệp	Độ phân giải	Tốc độ khung	Số khung	Thời lượng
A.mp4	1660×1244	24	121	5,0 s
B.mp4	1280×720	24	240	10,0 s
download.mp4	1080×1920	30	500	16,7 s

Nhận xét. Ba video này **không có nhãn thật**. Vì vậy mục này *không* báo cáo mAP hay bất kỳ độ đo chính xác nào — làm vậy sẽ là bịa số. Thay vào đó, phép kiểm chứng được thiết kế quanh những đại lượng quan sát được mà không cần nhãn, và quanh một dự đoán có thể sai: *nếu* điểm yếu thật nằm ở vật thể nhỏ, thì việc tăng độ phân giải đầu vào phải làm lộ ra thêm các phát hiện có **cạnh nhỏ** một cách chọn lọc, chứ không làm tăng đều số phát hiện ở mọi cỡ.

Ba cấu hình suy luận được so sánh, xử lý một trong mỗi mười khung hình, tổng cộng 87 khung hình cho mỗi cấu hình:

- **Cấu hình A** — kích thước ảnh 640, ngưỡng tin cậy 0,35, không cắt vùng quan tâm.
- **Cấu hình B** — kích thước ảnh 1280, ngưỡng tin cậy 0,20, cắt bỏ 30% đáy khung hình (vùng mặt đường và nắp ca-pô, không chứa biển báo).
- **Cấu hình C** — như B, cộng thêm suy luận theo lát cắt: khung hình được chia thành các ô 640 điểm ảnh chồng lấn 20%, mỗi ô chạy qua mô hình ở tỉ lệ gốc, kèm một lượt trên toàn khung hình, rồi gộp bằng NMS theo từng lớp.


Cần nói rõ: phép kiểm chứng này dùng trọng số của mô hình nền YOLOv8n trong ứng dụng trình diễn, *không phải* các mô hình YOLO26 ở những mục trên. Nó vì vậy không so sánh được trực tiếp với Bảng 4.1; mục đích của nó là kiểm chứng một *cơ chế*, không phải xếp hạng mô hình.

4.5.2 Kết quả

Bảng 4.8. Kết quả trên 87 khung hình mỗi cấu hình, tổng hợp cả ba video

Cấu hình	Số phát hiện	Trên mỗi khung	Tin cậy TB	Cạnh trung vị	Số lớp
A — 640, conf 0,35	185	2,13	0,618	4,49%	13
B — 1280, conf 0,20	431	4,95	0,633	3,00%	14
C — 1280 + lát cắt	644	7,40	0,616	2,84%	14

Số phát hiện tăng 2,3 lần từ A sang B và 3,5 lần từ A sang C. Nhưng con số quan trọng hơn nằm ở cột cuối: **cạnh trung vị của vật thể được phát hiện giảm** từ 4,49% xuống 2,84% cạnh khung hình. Nói cách khác, các cấu hình mới không chỉ tìm được *nhiều* biến hơn mà còn tìm được biến *nhỏ* hơn.



Hình 4.2. Phân bố kích thước vật thể được phát hiện trên video đường thật

4.5.3 Mức tăng phân bố không đều theo kích thước

Bảng 4.9 là kết quả then chốt của mục này.

Bảng 4.9. Số phát hiện theo nhóm kích thước và tỉ lệ tăng so với cấu hình A

Nhóm cạnh hộp	A	B	C	Tăng A→C
Rất nhỏ (< 2%)	34	134	206	6,1×
Nhỏ (2-4%)	39	159	261	6,7×
Vừa (4-8%)	107	131	155	1,4×
Lớn (≥ 8%)	5	7	22	—

Nhận xét. Nhóm vật thể vừa chỉ tăng **1,4 lần**, trong khi hai nhóm nhỏ tăng **6,1 và 6,7 lần**. Mức tăng hoàn toàn không đồng đều, và nó dồn đúng vào nhóm mà lý thuyết ở Mục 2.2.2 đã dự đoán. Đây là kiểm chứng độc lập cho luận điểm trung tâm của báo cáo, thu được trên dữ liệu ngoài phân bố và không cần nhấn thật.

4.5.4 Các phát hiện thêm có phải dương tính giả không?

Đây là phản biện hiển nhiên và cần được trả lời nghiêm túc: vì cấu hình B và C hạ ngưỡng tin cậy từ 0,35 xuống 0,20, một phần các phát hiện thêm có thể chỉ là nhiễu. Không có nhãn thật thì không thể loại trừ khả năng này hoàn toàn. Tuy nhiên có hai lập luận đáng cân nhắc.

Thứ nhất, độ tin cậy trung bình không sụt. Nếu các phát hiện thêm chủ yếu là nhiễu ở gần ngưỡng, trung bình phải kéo về phía 0,20. Thực tế nó giữ nguyên và thậm chí nhích lên: 0,618 ở cấu hình A so với 0,633 ở cấu hình B, dù sàn ngưỡng đã thấp hơn 15 điểm phần trăm. Điều này hàm ý phần lớn phát hiện mới có điểm cao, tức mô hình *thực sự* nhìn thấy chúng chứ không đoán mò.

Thứ hai, tính chọn lọc theo kích thước là chữ ký của tín hiệu thật. Nhiễu do hạ ngưỡng sẽ phân bố tương đối đều theo kích thước. Ở đây nhóm vừa gần như đứng yên trong khi nhóm nhỏ tăng gấp sáu lần — đúng dạng phân bố mà cơ chế “vật thể nhỏ mất chi tiết khi ảnh bị co” dự đoán, và không phải dạng mà nhiễu ngẫu nhiên tạo ra.

Dù vậy, kết luận đúng mực vẫn là: *dữ liệu quan sát được nhất quán với giả thuyết vật thể nhỏ*, chứ chưa phải bằng chứng dứt điểm. Muốn khẳng định chắc chắn phải gán nhãn thủ công một tập khung hình và tính *AP* thật — việc này được đưa vào hướng phát triển ở Chương 5.

4.5.5 Quan sát định tính



(a) Cấu hình A — 5 phát hiện



(b) Cấu hình B — 16 phát hiện

Hình 4.3. Cùng một khung hình của B.mp4 qua hai cấu hình suy luận

Hình 4.3 minh hoạ rõ hiện tượng. Cụm biển ở gần bên phải khung hình được phát hiện với độ tin cậy rất cao (0,94 đến 0,97) ở cả hai cấu hình — đây là chế độ “biển lớn” mà mô hình đã được dạy rất kỹ, đúng như phân tích thành phần dữ liệu ở Mục 3.1.4 đã chỉ ra. Ngược lại, cụm biển ở xa giữa khung hình chỉ xuất hiện ở cấu hình B và với độ tin cậy thấp hơn hẳn (0,23 đến 0,43). Khoảng cách về độ tin cậy giữa hai nhóm — hơn gấp đôi — cho thấy mô hình “chắc chắn” với biển gần và “lưỡng lự” với biển xa, dù cả hai đều là biển thật.

Một quan sát nữa đáng ghi nhận: 14 trong số 15 lớp xuất hiện trong kết quả, và lớp được phát hiện nhiều nhất là *Red Light* với 110 lần ở cấu hình B. Tuy nhiên đây cũng là lớp có nhiều khả năng bị dương tính giả nhất trên cảnh đường cao tốc, nơi hầu như không có đèn tín hiệu — một dấu hiệu nữa cho thấy cần nhấn thật trước khi kết luận về độ chính xác.

4.6 Bàn luận

Đối chiếu với các công trình đã nêu ở Chương 2, kết quả của đề tài tương đồng ở hai điểm và bổ sung thêm một điểm.

Điểm tương đồng thứ nhất là về điều kiện áp dụng của chứng cất tri thức. Bài báo gốc [3] xây dựng lập luận trên giả định tồn tại một mô hình thầy đủ mạnh và một khoảng cách năng lực đáng kể. Thực nghiệm ở đây, với khoảng cách chỉ 1,72 điểm phần trăm, rơi ra ngoài vùng giả định đó và cho kết quả âm — không mâu thuẫn với lý thuyết mà minh hoạ cho giới hạn của nó.

Điểm tương đồng thứ hai là về lượng tử hoá. Các nghiên cứu về lượng tử hoá số nguyên [4] nêu rõ rằng lợi ích tốc độ phụ thuộc vào nhân tính toán của phần cứng đích,

nhưng điều này thường bị lược bỏ trong các trình bày phổ thông. Thí nghiệm ở đây ghi nhận INT8 *chậm hơn* FP32 hơn hai lần, đúng như cảnh báo đó.

Điểm bổ sung, và cũng là đóng góp riêng của đề tài, nằm ở cách đo. Các báo cáo về nén mô hình thường tổng kết bằng một câu dạng “giảm 70% dung lượng, chỉ mất 0,4% mAP”. Kết quả ở đây cho thấy câu tổng kết đó, dù không sai, vẫn có thể gây hiểu nhầm nghiêm trọng: cùng phép can thiệp ấy làm *AP* trên vật thể nhỏ giảm gấp 6,5 lần. Với những bài toán mà vật thể nhỏ mới là trường hợp quan trọng — phát hiện biển báo giao thông là một ví dụ điển hình — việc chỉ báo cáo mAP tổng là không đủ. Kiến nghị rút ra là mọi báo cáo về nén mô hình cho bài toán phát hiện nên kèm *AP* tách theo nhóm kích thước, và chi phí bổ sung để có chỉ số này gần như bằng không nếu đã dùng bộ đánh giá COCO.

CHƯƠNG 5 : TỔNG KẾT

5.1 Tóm lược kết quả đạt được

Đề tài đã khảo sát hai kỹ thuật nén mô hình — chưng cất tri thức và lượng tử hoá sau huấn luyện — cho bài toán phát hiện biến báo giao thông, trên bộ dữ liệu *pkdarabi/cardetection* gồm 4.969 ảnh với 6.012 hộp bao thuộc 15 lớp. Năm cấu hình được huấn luyện và đánh giá trong cùng một lượt chạy, bằng cùng một bộ tính độ đo.

Đối chiếu với ba câu hỏi nghiên cứu đặt ra ở Chương 1:

Câu hỏi 1.1 về chưng cất tri thức nhận câu trả lời *phủ định*. Mô hình học trò được chưng cất đạt $mAP@0,5$ bằng 0,9014, thấp hơn chính nó khi huấn luyện thông thường (0,9348) 3,34 điểm phần trăm. Cơ chế chưng cất đã được xác minh là thực sự hoạt động thông qua cột mất mát riêng trong nhật ký huấn luyện, giảm từ 12,1663 xuống 1,1608. Nguyên nhân khả dĩ nhất là khoảng cách năng lực giữa thầy và trò quá hẹp — chỉ 1,72 điểm phần trăm — khiến lượng tri thức có thể truyền đạt không bù nổi chi phí nhiễu.

Câu hỏi 1.2 về lượng tử hoá cho thấy một sự đánh đổi phức tạp hơn nhiều so với thường được trình bày. Về dung lượng, INT8 đạt mục tiêu rõ ràng: giảm 70,3%. Về tốc độ, kết quả trái ngược kỳ vọng — bản INT8 chậm hơn bản FP32 hơn hai lần do môi trường thực thi không có nhân tính toán số nguyên được tối ưu. Về độ chính xác, $mAP@0,5$ chỉ giảm 0,0038 nhưng AP trên vật thể nhỏ giảm 0,0247.

Câu hỏi 1.3 về tính đại diện của mAP tổng là câu hỏi thu được câu trả lời có giá trị nhất. Mức suy giảm trên vật thể nhỏ lớn gấp 1,9 lần mAP tổng ở phép chưng cất, và gấp 6,5 lần ở phép lượng tử hoá. Nguyên nhân nằm ở phân bố dữ liệu: 51,30% số hộp bao thuộc nhóm lớn — nhóm mà mọi cấu hình đều xử lý tốt như nhau — nên chúng chi phối giá trị trung bình và pha loãng suy giảm ở nhóm khó.

5.2 Đóng góp

Ba đóng góp chính có thể rút ra.

Thứ nhất, về mặt phương pháp thực nghiệm, đề tài thiết lập một thiết kế có đối chứng đúng nghĩa: mô hình học trò được huấn luyện hai lần với cùng số chu kỳ, cùng hạt ngẫu nhiên, cùng kích thước ảnh, chỉ khác ở việc bật hay tắt chưng cất. Kèm theo đó là năm ngưỡng chấp nhận khai báo trước khi chạy, và cơ chế xác minh rằng kỹ thuật khảo sát đã thực sự được kích hoạt.

Thứ hai, và quan trọng nhất, đề tài cung cấp bằng chứng định lượng cho thấy **mAP tổng che giấu chi phí thật của việc nén mô hình**. Một cấu hình được tổng kết là “giảm 70% dung lượng, chỉ mất 0,4% mAP” thực chất mất 2,47 điểm phần trăm ở nhóm vật thể nhỏ. Với bài toán biển báo giao thông, nơi biển ở xa quyết định thời gian phản ứng của xe, sự khác biệt này có ý nghĩa an toàn trực tiếp. Kiến nghị rút ra là mọi báo cáo về nén mô hình cho bài toán phát hiện nên kèm *AP* tách theo nhóm kích thước — chi phí bổ sung gần như bằng không nếu đã dùng bộ đánh giá COCO.

Ngoài ra, luận điểm này được kiểm chứng độc lập trên dữ liệu ngoài phân bố: trên ba đoạn video đường phố, việc tăng độ phân giải đầu vào làm số phát hiện ở nhóm vật thể nhỏ tăng 6,1 lần trong khi nhóm vừa chỉ tăng 1,4 lần. Tính chọn lọc theo kích thước này là chữ ký của cơ chế đã nêu, chứ không phải của nhiễu ngẫu nhiên.

Thứ ba, đề tài chỉ ra hai vấn đề của một bộ dữ liệu công khai đang được dùng rộng rãi: 38,68% số ảnh là ảnh cắt cận cảnh kiểu GTSRB khiến phân bố kích thước bị lưỡng cực, và 10,2% tập kiểm tra có bản sao trong tập huấn luyện.

5.3 Hạn chế

Đề tài có những hạn chế sau, được nêu đầy đủ để người đọc đánh giá đúng phạm vi giá trị của kết quả.

Kích thước lô không đồng nhất giữa hai nhánh học trò. Nhánh chưng cất dùng lô 8, nhánh đối chứng dùng 24, do ràng buộc bộ nhớ card đồ hoạ khi phải nạp đồng thời cả hai mô hình. Đây là yếu tố gây nhiễu chưa kiểm soát được, và vì nó, kết luận đúng đắn là “trong cấu hình cụ thể này, chưng cất không mang lại lợi ích” chứ không phải “chưng cất có hại”.

Hệ số chưng cất chưa được quét. Giá trị 6,0 là mặc định của thư viện. Không loại trừ khả năng một giá trị nhỏ hơn sẽ cho kết quả khác.

Bộ dữ liệu có rò rỉ giữa các tập. 65 trong số 638 ảnh kiểm tra có bản sao trong tập huấn luyện, tức 10,2%. Mọi con số mAP tuyệt đối vì vậy nên được hiểu là cận trên. Các phép so sánh tương đối ít bị ảnh hưởng hơn vì rò rỉ tác động như nhau tới cả năm cấu hình.

Chỉ khảo sát một cặp thầy–trò. Kết luận về chưng cất được rút ra từ đúng một cặp YOLO26s–YOLO26n. Muốn kết luận tổng quát cần khảo sát nhiều cặp có khoảng cách năng lực khác nhau.

Lượng tử hoá chỉ đo trên một môi trường thực thi. Kết quả tốc độ của INT8 phụ thuộc mạnh vào nhân tính toán của phần cứng đích, nên con số thu được ở đây không nên

tổng quát hoá cho các môi trường khác.

Tập lớp bị giới hạn. Mười lăm lớp chỉ gồm đèn tín hiệu và biển giới hạn tốc độ. Các nhóm biển cấm, biển nguy hiểm và biển chỉ dẫn hoàn toàn không có trong tập nhãn, nên mô hình không thể phát hiện chúng dù chất lượng huấn luyện có tốt đến đâu.

Phép kiểm chứng trên video không có nhãn thật. Ba đoạn video ở Mục 4.5 chưa được gán nhãn, nên mục đó chỉ báo cáo các đại lượng quan sát được chứ không báo cáo độ chính xác. Không thể loại trừ hoàn toàn khả năng một phần phát hiện thêm là dương tính giả, dù độ tin cậy trung bình không sụt và tính chọn lọc theo kích thước đều nghiêng về giả thuyết ngược lại. Ngoài ra phép kiểm chứng này dùng trọng số YOLOv8n của ứng dụng trình diễn chứ không phải các mô hình YOLO26 ở những mục khác, nên không so sánh trực tiếp được.

Chưa đo trên tập kiểm tra sạch. Báo cáo đã xác định được 573 ảnh không bị rò rỉ nhưng chưa tính lại toàn bộ chỉ số riêng trên tập con này.

5.4 Hướng phát triển

Các hướng phát triển được sắp theo thứ tự ưu tiên, từ chi phí thấp tới chi phí cao.

Ưu tiên 1 — Đo lại trên tập kiểm tra sạch. Tập 573 ảnh không rò rỉ đã được xác định; chỉ cần chạy lại khâu đánh giá trên tập con này để có bộ số không bị thổi phồng. Chi phí gần như bằng không vì không phải huấn luyện lại.

Ưu tiên 2 — Chạy lại nhánh chưng cất với kích thước lô đồng nhất. Dùng tích lũy gradient để đạt kích thước lô hiệu dụng bằng 24 như nhánh đối chứng, qua đó loại bỏ yếu tố gây nhiễu lớn nhất hiện nay. Chỉ sau bước này mới có thể kết luận chắc chắn về tác dụng của chưng cất.

Ưu tiên 3 — Quét hệ số chưng cất. Thử các giá trị nhỏ hơn 6,0 để kiểm chứng giả thuyết rằng thành phần bất chước đang lấn át tín hiệu từ nhãn cứng.

Ưu tiên 4 — Mở rộng khoảng cách thầy-trò. Dùng một mô hình thầy lớn hơn hẳn để tạo khoảng cách năng lực đủ rộng, qua đó kiểm chứng trực tiếp giả thuyết về điều kiện áp dụng của chưng cất.

Ưu tiên 5 — Làm sạch và cân bằng lại bộ dữ liệu. Loại bỏ các ảnh trùng, sau đó thử huấn luyện lại khi đã loại hoặc giảm mạnh nhóm 1.922 ảnh kiểu GTSRB. Giả thuyết là mAP tổng sẽ giảm nhưng AP trên nhóm vật thể nhỏ sẽ tăng — bản thân việc kiểm chứng giả thuyết này đã là một thí nghiệm có giá trị.

Ưu tiên 6 — Gán nhãn một tập khung hình video và đo AP thật. Phép kiểm chứng ở Mục 4.5 mới dừng ở mức nhất quán với giả thuyết. Gán nhãn thủ công vài trăm khung hình từ ba video đã có sẽ biến nó thành một phép đo AP đúng nghĩa trên dữ liệu ngoài phân bố — thứ có giá trị hơn hẳn mọi chỉ số trên tập kiểm tra cùng phân bố.

Ưu tiên 7 — Điều chỉnh kiến trúc cho vật thể nhỏ. Vì toàn bộ phân tích ở Chương 4 đều chỉ về nhóm vật thể nhỏ, hướng cải thiện tự nhiên là bổ sung đầu dự đoán P2 hoạt động ở bước sải 4 thay vì 8, hoặc huấn luyện ở kích thước ảnh lớn hơn. Đây là biện pháp rẻ hơn nhiều so với chuyển sang một mô hình lớn hơn.

Ưu tiên 8 — Bổ sung dữ liệu đúng miền. Không kỹ thuật nào thay thế được dữ liệu thật đúng miền. Nếu cần bổ sung dữ liệu công khai, TT100K [25] và Mapillary Traffic Sign [26] là hai lựa chọn phù hợp vì đều là ảnh cảnh đường thật, qua đó lấp được đúng vùng kích thước trung gian mà bộ dữ liệu hiện tại đang thiếu.

TÀI LIỆU THAM KHẢO

- [1] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [2] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” <https://github.com/ultralytics/ultralytics>, 2023.
- [3] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” *arXiv preprint arXiv:1503.02531*, 2015.
- [4] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko, “Quantization and training of neural networks for efficient integer-arithmetic-only inference,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 2704–2713.
- [5] K. Tong, Y. Wu, and F. Zhou, “Recent advances in small object detection based on deep learning: A review,” *Image and Vision Computing*, vol. 97, p. 103910, 2020.
- [6] J. M. Johnson and T. M. Khoshgoftaar, “Survey on deep learning with class imbalance,” *Journal of Big Data*, vol. 6, no. 1, p. 27, 2019.
- [7] B. Barz and J. Denzler, “Do we train on test data? purging CIFAR of near-duplicates,” *Journal of Imaging*, vol. 6, no. 6, p. 41, 2020.
- [8] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, “Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition,” *Neural Networks*, vol. 32, pp. 323–332, 2012.
- [9] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2017.
- [10] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, “SSD: Single shot multibox detector,” in *European Conference on Computer Vision (ECCV)*, 2016, pp. 21–37.

- [11] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *European Conference on Computer Vision (ECCV)*, 2014, pp. 740–755.
- [12] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [13] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, “Feature pyramid networks for object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.
- [14] Z. Zheng, P. Wang, W. Liu, J. Li, R. Ye, and D. Ren, “Distance-IoU loss: Faster and better learning for bounding box regression,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, 2020, pp. 12 993–13 000.
- [15] X. Li, W. Wang, L. Wu, S. Chen, X. Hu, J. Li, J. Tang, and J. Yang, “Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 21 002–21 012, 2020.
- [16] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The PASCAL visual object classes (VOC) challenge,” *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.
- [17] G. Chen, W. Choi, X. Yu, T. Han, and M. Chandraker, “Learning efficient object detection models with knowledge distillation,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [18] Q. Li, S. Jin, and J. Yan, “Mimicking very efficient network for object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 6356–6364.
- [19] J. Gou, B. Yu, S. J. Maybank, and D. Tao, “Knowledge distillation: A survey,” *International Journal of Computer Vision*, vol. 129, no. 6, pp. 1789–1819, 2021.

- [20] R. Krishnamoorthi, “Quantizing deep convolutional networks for efficient inference: A whitepaper,” *arXiv preprint arXiv:1806.08342*, 2018.
- [21] M. Nagel, M. Fournarakis, R. A. Amjad, Y. Bondarenko, M. van Baalen, and T. Blankevoort, “A white paper on neural network quantization,” *arXiv preprint arXiv:2106.08295*, 2021.
- [22] A. Gholami, S. Kim, Z. Dong, Z. Yao, M. W. Mahoney, and K. Keutzer, “A survey of quantization methods for efficient neural network inference,” in *Low-Power Computer Vision*, 2022, pp. 291–326.
- [23] P. Micikevicius, S. Narang, J. Alben, G. Diamos, E. Elsen, D. Garcia, B. Ginsburg, M. Houston, O. Kuchaiev, G. Venkatesh, and H. Wu, “Mixed precision training,” in *International Conference on Learning Representations (ICLR)*, 2018.
- [24] S. Houben, J. Stallkamp, J. Salmen, M. Schlipsing, and C. Igel, “Detection of traffic signs in real-world images: The German traffic sign detection benchmark,” in *International Joint Conference on Neural Networks (IJCNN)*, 2013, pp. 1–8.
- [25] Z. Zhu, D. Liang, S. Zhang, X. Huang, B. Li, and S. Hu, “Traffic-sign detection and classification in the wild,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 2110–2118.
- [26] C. Ertler, J. Mislej, T. Ollmann, L. Porzi, G. Neuhold, and Y. Kuang, “The Mapillary traffic sign dataset for detection and classification on a global scale,” in *European Conference on Computer Vision (ECCV)*, 2020, pp. 68–84.
- [27] A. Torralba and A. A. Efros, “Unbiased look at dataset bias,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2011, pp. 1521–1528.
- [28] B. Recht, R. Roelofs, L. Schmidt, and V. Shankar, “Do ImageNet classifiers generalize to ImageNet?” in *International Conference on Machine Learning (ICML)*, 2019, pp. 5389–5400.
- [29] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal speed and accuracy of object detection,” *arXiv preprint arXiv:2004.10934*, 2020.

- [30] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, no. 1, p. 60, 2019.
- [31] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga *et al.*, “PyTorch: An imperative style, high-performance deep learning library,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [32] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.

PHỤ LỤC

Phụ lục liệt kê tài nguyên và chi tiết kỹ thuật phục vụ việc tái lập kết quả đề tài.

A. Tài nguyên công khai

Bảng .1. Tài nguyên sử dụng trong đề tài

Tài nguyên	Địa chỉ / định danh
Bộ dữ liệu	https://www.kaggle.com/datasets/pkdarabi/cardetection
Trọng số mô hình thầy	yolo26s.pt — Ultralytics, tiền huấn luyện trên COCO
Trọng số mô hình trò	yolo26n.pt — Ultralytics, tiền huấn luyện trên COCO
Thư viện phát hiện	Ultralytics YOLO [2]
Bộ tính độ đo	pycocotools trên định dạng COCO [11]
Nền tảng học sâu	PyTorch [31]
Môi trường huấn luyện	Kaggle Notebook, GPU Tesla T4
Sổ tay thực nghiệm	notebooks/giaidoan2.ipynb

B. Danh sách lớp

Mười lăm lớp được giữ nguyên theo bộ dữ liệu gốc, không gộp và không ánh xạ lại:

Bảng .2. Danh sách 15 lớp và mã tương ứng

Mã	Tên lớp	Mã	Tên lớp
0	Green Light	8	Speed Limit 40
1	Red Light	9	Speed Limit 50
2	Speed Limit 10	10	Speed Limit 60
3	Speed Limit 100	11	Speed Limit 70
4	Speed Limit 110	12	Speed Limit 80
5	Speed Limit 120	13	Speed Limit 90
6	Speed Limit 20	14	Stop
7	Speed Limit 30		

C. Cách chạy lại quy trình

Mỗi bước của quy trình là một mô-đun độc lập, gọi được trực tiếp từ dòng lệnh:

```
# 1. Kiểm tra dữ liệu và đóng gói tệp cấu hình
```

```

2 python -m src.data.inspect_dataset --write-configs
3
4 # 2. Kiểm tra chất lượng nhãn
5 python -m src.data.validate_labels
6
7 # 3. Phân tích khám phá dữ liệu
8 python -m src.eda.class_distribution
9 python -m src.eda.bbox_statistics
10 python -m src.eda.image_statistics
11 python -m src.eda.heatmap_analysis
12
13 # 4. Chạy bộ kiểm thử tự động (chỉ cần CPU, khoảng 1 giây)
14 pytest
15
16 # 5. Kiểm chứng trên video đường thật (chỉ cần CPU)
17 python scripts/eval_videos.py --stride 10
18
19 # Phân huan luyện, xuất ONNX và đánh giá bằng pycocotools nằm trong
20 # notebooks/giaidoan2.ipynb (cần GPU, ước tính ~3 giờ trên Tesla T4).
21 # Đặt RUN_MODE = "SMOKE_TEST" để chạy thử toàn bộ đường ống trong vài phút.

```

Listing 1. Các lệnh chạy lại phần phân tích dữ liệu

D. Bảng ánh xạ hình vẽ và nguồn dữ liệu

Mọi hình và bảng số liệu trong báo cáo đều được sinh ra từ dữ liệu thật, không có số liệu minh họa. Bảng .3 chỉ rõ nguồn của từng nhóm.

Bảng .3. Ánh xạ giữa nội dung báo cáo và tệp kết quả sinh ra bởi quy trình

Nội dung trong báo cáo	Nguồn
Bảng thống kê tổng quan	results/tables/dataset_summary.csv
Bảng và hình phân bố lớp	results/tables/class_distribution.csv
Bảng phân nhóm kích thước	results/tables/bbox_size_categories.csv
Thống kê ảnh	results/tables/image_statistics.csv
Báo cáo chất lượng nhãn	results/tables/data_quality_report.csv
Ma trận nhầm lẫn	Thư mục chạy của Ultralytics
Bảng thành phần bộ dữ liệu	Phân tích bổ sung theo quy ước đặt tên tệp
Toàn bộ bảng kết quả, AP theo kích thước, độ trễ, kiểm toán rò rỉ	notebooks/giaidoan2.ipynb
Kiểm chứng trên video đường thật	scripts/eval_videos.py → results/video_eval/

E. Ghi chú về tính tái lập

Hạt ngẫu nhiên mặc định là 42, được đặt cho biến môi trường băm của Python, thư viện ngẫu nhiên chuẩn, NumPy, PyTorch và PyTorch CUDA. Chế độ tắt định của cuDNN được bật và chế độ tự dò thuật toán nhanh nhất được tắt — điều này làm chậm huấn luyện một chút nhưng là điều kiện cần để kết quả lặp lại được giữa các lần chạy.

Cần lưu ý rằng ngay cả khi đã gieo hạt đầy đủ, kết quả vẫn có thể sai khác nhỏ giữa các phiên bản thư viện, các kiến trúc GPU khác nhau và giữa chế độ CPU với GPU. Các con số trong báo cáo được đo trên môi trường Kaggle Notebook với GPU Tesla T4 tại thời điểm thực hiện đề tài.